

Применимость процессов Хокса для предсказания пользовательской активности в e-commerce

Алексей Мошкин

МКН СПбГУ

Научный руководитель: Николаев Максим Сергеевич

2026

Аннотация

Работа посвящена применению процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce. Прогноз пользовательской активности - важный блок при оценке ценности клиента, планировании коммуникаций с ним и подведении итогов А/В-экспериментов. Точные модели интенсивности позволяют не только улучшать бизнес-метрики, но и интерпретировать структуру пользовательского поведения. А процессы Хокса с экспоненциальным ядром естественно описывают самовозбуждение и кросс-канальное влияние событий и при этом сохраняют легко интерпретируемые параметры, что выгодно отличает их от более сложных моделей машинного обучения, например бустингов.

Актуальность работы обусловлена тем, что в индустриальных задачах с разреженными счётчиками (доля нулей в нашем датасете - 93.7%) большинство стандартных регрессионных методов теряет в качестве из-за дисбаланса, тогда как явная вероятностная модель с Хоукс ядрами остаётся стабильной и легко интерпретируется. В работе исследуется не только предсказательное качество Хоукс-моделей, но и их сходимость, чувствительность к выбору регуляризации, идентифицируемость коэффициентов и поведение на разных длинах обучающего окна - то есть аспекты, важные для практического применения модели.

В качестве данных используется датасет из 10K пользователей крупного маркетплейса за 290 дней с пятью поведенческими счётчиками (`searches`, `cat_to_cart`, `cat_to_ord`, `to_cart`, `to_ord`). Основной target - число покупок `to_ord` на пару (`user`, `day`). Все эксперименты проводятся на воспроизводимом коде на Python.

Основные результаты: построена иерархия из шести вероятностных моделей с переходом от Global Poisson к Joint Hawkes; на главном 207-дневном train-test разбиении Хоукс-надстройка устойчиво улучшает персонализированный пуассоновский бейзлайн на трёх независимых каналах; кросс-канальная матрица $\alpha \in \mathbb{R}^{3 \times 3}$ восстановлена в виде нижнетреугольной структуры воронки `searches` $\rightarrow$ `to_cart` $\rightarrow$ `to_ord`. Через ландшафт лосса показано, что диагональные коэффициенты слабо идентифицируемы, что согласуется с известными результатами по многоядерным Хоукс процессам [4, 5]; бустинг на богатых данных после feature-engineering (построена 141 фича) даёт верхнюю планку качества, но с менее интерпретируемой структурой. Дополнительно проведёно исследование, показывающие, что эффект от Хоукс ядер сильно скоррелирован с

настройками базовой интенсивности, за счет этого возможен "переток массы" между Хоукс-частью и базовой интенсивностью без значительной потери качества, из-за чего выбор регуляризации (численной или структурной) очень важен, так как именно он регулирует где осядет масса. Особенно сильно этот эффект проявляется на коротких train-test окнах, где в зависимости от регуляризации веса Хоукс ядер могут полностью обнулиться.

Contents

Аннотация	1
1 Введение	3
1.1 Постановка задачи и актуальность	3
1.2 Процессы Хоукса: специфика и применимость к задаче	3
1.3 Цели и задачи работы	5
1.4 Используемые данные	5
2 Обзор литературы	6
3 Разведочный анализ данных и метрика качества	7
3.1 Структура датасета и разреженность	7
3.2 Дневная интенсивность на полном ряду	7
3.3 Гетерогенность пользователей	8
3.4 Корреляции каналов и выбор признаков для Hawkes	10
3.5 Метрика качества: per-observation Poisson NLL и saturated floor	11
4 Часть I. Бейзлайн и Хоукс-надстройка на полном train-test	13
4.1 Постановка: зачем нужен сильный бейзлайн	13
4.2 Построение бейзлайна	13
4.3 Scaled-baseline Hawkes на персонализированной базе	16
4.4 Joint Hawkes как альтернативная параметризация	18
4.5 Бустинг и feature engineering	19
4.6 Итоговая лестница моделей	19
5 Часть II. Поведение моделей на коротких train-окнах	23
5.1 Blockwise CV: 21-дневные блоки	23
5.2 Вырождение Scaled-baseline Hawkes	24
5.3 Joint Hawkes на коротких окнах	24
5.4 Train-length scan и crossover'ы	25
6 Часть III. Структура cross-channel Хоукс-матрицы	27
6.1 Cross-channel постановка и верификация	27
6.2 Чувствительность к регуляризации	28
6.3 Profile likelihood и асимметрия диагонали/внедиагональных	31
6.4 Интервалы 10%-gain и финальная матрица	33

6.5	Per-user визуализация работы моделей	36
7	Заключение	39

1 Введение

1.1 Постановка задачи и актуальность

Задача предсказания пользовательской активности - одна из центральных в современном e-commerce. Точная оценка ожидаемого числа покупок `to_ord` на пару (`user`, `day`) может напрямую использоваться в персонализации ранжирования, расчёте CLV и подведении итогов A/B-экспериментов.

С формальной точки зрения мы оцениваем дневную интенсивность $\lambda_{u,t}$ и предполагаем условную Пуассоновскую модель наблюдения:

$$y_{u,t} \mid \lambda_{u,t} \sim \text{Poisson}(\lambda_{u,t}),$$

где $y_{\{u,t\}}$ - число покупок пользователя u в день t , а $\lambda_{u,t}$ - наша точечная оценка интенсивности. Задача состоит в предсказании $\lambda_{u,t}$ на отложенную тестовую выборке.

Особенность задачи - крайняя разреженность сигнала: в наших данных среднее число покупок на (`user`, `day`) ≈ 0.10 , а доля нулевых ячеек - 93.7%. Такие данные плохо подходят к классическим регрессионным методам, ориентированным на нормальные ошибки, и требуют явного учёта Пуассоновского распределения наблюдений. Дополнительная сложность - сильное различие в поведении пользователей: разброс по среднему числу покупок между пользователями на порядки превышает изменчивость во времени, поэтому без персонализации модель работает плохо.

Третья особенность - событийный характер сигнала. Покупки не происходят равномерно во времени: часто наблюдаются «вспышки» активности (пользователь сделал серию заказов за один-два дня) с последующей длительной паузой. Для моделирования такой динамики могут применяться self-exciting процессы, в котором недавние события явно влияют на интенсивность будущих событий, и.

Актуальность работы определяется тремя факторами. Во-первых, индустриальные системы прогноза покупок чаще всего опираются на слабо интерпретируемые модели (GBDT, нейросети), которые дают хороший скор, но не дают понимания структуры пользовательского поведения. Во-вторых, при оценке эффектов A/B-экспериментов важно не только качество прогноза, но и стабильность модели на коротких окнах и интерпретируемость её параметров - здесь GBDT с сотнями признаков становится плохо контролируемым инструментом. В-третьих, процессы Хокса, успешно применявшиеся в финансах [2] и анализе кликовых потоков [3, 7], редко рассматриваются в индустриальном e-commerce как полноценный инструмент - несмотря на то, что их параметры (`per-user multiplier`, матрица α -взаимодействий) допускают прямую бизнес-интерпретацию.

1.2 Процессы Хокса: специфика и применимость к задаче

Процесс Хокса - это самовозбуждающийся точечный процесс, в котором интенсивность будущих событий зависит от истории уже случившихся [1]. В классической непрерывной форме одномерный процесс с экспоненциальным ядром записывается как

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha \cdot \exp(-\beta(t - t_i)),$$

где μ - фоновая интенсивность, α - вес возбуждения, а β - скорость затухания сигнала. Каждое произошедшее событие повышает интенсивность в ближайшем

будущем. Свойство "памяти" этого процесса - конечное: после нескольких полураспадов событие фактически перестаёт влиять на текущую интенсивность.

В многомерной форме (K типов событий) ядра становятся матричными:

$$\lambda_k(t) = \mu_k + \sum_{j=1}^K \sum_{t_i^{(j)} < t} \alpha_{kj} \cdot \exp\left(-\beta_{kj}(t - t_i^{(j)})\right).$$

Здесь α_{kj} интерпретируется как «сила влияния события типа j на интенсивность типа k». Эта матричная структура и есть та самая cross-channel матрица, которая в нашей работе восстанавливается для воронки `searches → to_cart → to_ord`.

В дискретно-дневной форме, удобной для нашей задачи, мы пишем

$$\lambda_{u,t} = \underbrace{\mu_{u,t}}_{\text{baseline}} + \sum_j \alpha_j \cdot z_{u,j,t},$$

где $\mu_{u,t}$ - уверенный бейзлайн пользовательской интенсивности, построим его чуть позже, а $z_{u,j,t}$ - экспоненциально сглаженный счётчик j-ой фичи у пользователя u до дня t:

$$z_{u,j,t} = \sum_{s < t} x_{u,j,s} \cdot \exp\left(-\frac{t-s}{\tau_j}\right),$$

с заданным полураспадом τ_j (в большинстве экспериментов мы используем $\tau \in \{1, 3\}$ дня). Веса α_j оцениваются по обучающей выборке и допускают прямую интерпретацию: положительный α_j означает, что событие фичи j повышает интенсивность будущих покупок этого пользователя.

Применимость процессов Хокса к нашей задаче объясняется следующими свойствами:

1. **Self-excitation естественно описывает воронку покупок.** В e-commerce покупка не происходит «из ниоткуда»: ей часто предшествует серия поисков, просмотров и добавлений в корзину. Hawkes явно моделирует эту короткую память.
2. **Параметры интерпретируемы.** Матрица $\alpha[target \leftarrow source]$ показывает, какие каналы и в какой мере возбуждают другие каналы. Это даёт бизнес-понимание, недоступное у GBDT.
3. **Аддитивная декомпозиция бейзлайн + надстройка.** Модель явно разделяет «фоновую активность» пользователя и «короткие всплески от событий», что позволяет независимо изучать обе компоненты.

Платой за интерпретируемость становится более ограниченная функциональная форма: линейная additive комбинация $\lambda_u \cdot b_t + \alpha^\top z$ игнорирует нелинейные взаимодействия признаков, которые GBDT мог бы учесть. Оценка того, насколько много полезной информации при таком упрощении мы теряем - одна из задач работы.

1.3 Цели и задачи работы

Цель работы: исследовать границы применимости процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce, оценить их предсказательное качество и стабильность по сравнению с вероятностным бейзлайном и бустинговой моделью, а также изучить идентифицируемость и интерпретируемость их коэффициентов.

Задачи работы:

1. Построить иерархию вероятностных моделей, дающую устойчивый бейзлайн для последующей Хоукс-надстройки.
2. Исследовать особенности сходимости коэффициентов Хоукс-моделей: на каком объёме train они стабилизируются и какая параметризация подходит для коротких окон.
3. Восстановить cross-channel матрицу $\alpha[target \leftarrow source]$ для трёх каналов воронки и оценить её устойчивость к выбору train-окна и регуляризации.
4. Сравнить Хоукс-модель с двумя контрольными моделями - статистическим бейзлайном и бустингом на расширенном feature-engineering'e датасете - на нескольких train-test разбиениях.

1.4 Используемые данные

Все эксперименты проводятся на открытом датасете, обезличенно отражающем поведение 10000 случайно выбранных пользователей крупного e-commerce-сервиса за период 2025-01-15..2025-10-31 (290 дней). На каждую пару (user, day) доступны пять поведенческих счётчиков (число событий за день):

- `searches` - пользовательские поиски, mean ≈ 1.20 событий на строку;
- `cat_to_cart` - переходы из категории в корзину;
- `cat_to_ord` - переходы из категории к оформлению заказа;
- `to_cart` - добавления товаров в корзину, mean ≈ 0.37 ;
- `to_ord` - оформленные заказы (target), mean ≈ 0.10 .

Структура данных - длинный pandas DataFrame с ~2.87M строк формы (user_id, event_date, searches, to_cart, to_ord, ...). Все ячейки заполнены явно: даже если пользователь в какой-то день не проявлял активности, в датасете присутствует строка с нулями. Это упрощает построение rolling-агрегатов и Hawkes-states одной свёрткой по каждому пользователю.

2 Обзор литературы

Процессы Хокса как класс самовозбуждающихся точечных процессов введены Хоксом [1] и долгое время применялись преимущественно в сейсмологии и финансах [2]. С развитием современных систем сбора пользовательских данных интерес к ним смещается в сторону анализа кликовых потоков, рекомендательных систем и e-commerce.

Существенная часть современной литературы посвящена нейронным расширениям Хоукс-моделей. Du et al. [3] предложили recurrent marked temporal point processes (RMTPP), в которых дискретная история событий пользователя сжимается рекуррентной сетью в вектор состояния, по которому затем предсказывается интенсивность будущих событий. Mei и Eisner [7] развили эту идею в neural Hawkes process, явно параметризовав интенсивность нейросетью, сохраняющей формальную структуру self-exciting процесса. Эти подходы дают высокое качество, но за счёт интерпретируемости: нейросетевой блок становится чёрным ящиком, и непосредственно «прочитать» матрицу cross-channel влияний из обученной модели нельзя.

Параллельно развиваются классические multivariate Хоукс-модели с акцентом именно на интерпретируемость и идентифицируемость. Bacry, Bompierre, Gaïffas и Muzy [4] показывают, что при оценке коэффициентов многомерного Хоукс-процесса по максимальному правдоподобию имеет смысл регуляризовать диагональные элементы матрицы влияния отдельно от внедиагональных: первые отвечают за «свой» self-excitation канала и часто коллинеарны фоновой интенсивности μ , вторые описывают cross-channel взаимодействия и идентифицируются устойчивее. В нашей работе мы наблюдаем эту же асимметрию эмпирически (см. часть III) и связываем её с тем же механизмом коллинеарности history-state и baseline. Параллельно Achab et al. [5] предложили отказ от MLE в пользу integrated cumulants, чтобы обойти проблему non-identifiability диагональных коэффициентов на коротких выборках; их подход не требует точной формы ядер и масштабируется к большим K через спектральные разложения матриц моментов.

В индустриальном контексте предсказания пользовательской активности классическим инструментом остаются модели семейства Pareto/NBD и Beta-Geometric, восходящие к работам Fader и Hardie [6]. Их центральная идея - Gamma-prior на индивидуальный темп покупок пользователя λ_u , с регуляризацией оценки через Empirical-Bayes posterior. Этот же приём используется нами в Personalized Gamma-Poisson бейзлайне и оказывается основным шагом, дающим крупнейший выигрыш по NLL: при $(\alpha, \beta) \approx (0.88, 0.88)$ модель аккуратно ранжирует пользователей по их «истинному» темпу и обеспечивает устойчивую базу для последующей Хоукс-надстройки.

Наконец, для сравнения с интерпретируемой моделью используются современные бустинговые методы, в первую очередь Gradient Boosting Machines в реализации Friedman [8] и их продвинутые версии (HistGradientBoosting, LightGBM, CatBoost). На широком feature-engineering'e такие модели дают верхнюю планку по качеству, особенно когда сигнал содержит нелинейные взаимодействия признаков, плохо схватываемые линейной additive формой Hawkes. Однако они не дают структурных коэффициентов, сопоставимых с матрицей α Хоукс-процесса, и поэтому используются в работе как control, а не как самостоятельная цель.

3 Разведочный анализ данных и метрика качества

3.1 Структура датасета и разреженность

Панель данных представляет собой плотную таблицу ($\text{user} \times \text{day}$) без пропусков: для каждого из 10K пользователей доступны строки на все 290 дней анализируемого периода (нулевые счётчики записаны явно).

Распределение таргета `to_ord` крайне разреженное. Гистограмма числа покупок на `user-day` ($\log\text{-Y}$) показана на рис. 1.




Figure 1: Распределение числа покупок на `user-day` ($\log\text{-Y}$)

Видны три структурных факта:

- Подавляющее большинство ячеек содержат нули - точнее, 93.7% строк датасета имеют `to_ord = 0`.
- Существует тяжёлый правый хвост: единичные (`user, day`)-пары содержат десяток покупок и больше, при максимуме порядка сотни. Это означает, что распределение `to_ord` имеет крайне тяжелые хвосты.
- При этом среднее по данным ≈ 0.10 - и есть та самая разреженность сигнала.

Эта картина мотивирует две вещи. Во-первых, использовать именно Пуассоновскую модель наблюдения, а не нормальную регрессию - иначе при 93.7% нулей оптимум прогноза вырождается в константу около нуля. Во-вторых, явно учитывать пер-юзерную гетерогенность через какую-то персонализации.

Распределение активности по пользователям тоже крайне неравномерное: 18% самых активных пользователей делают 62% всех покупок. Это в духе классического правила Парето и согласуется с эмпирическими наблюдениями из работ по CLV [6].

3.2 Дневная интенсивность на полном ряду

Агрегированная по дням дневная интенсивность `to_ord` представлена на рис. 2.

На полном ряду выделяются три режима:




Figure 2: Дневная интенсивность `to_ord` на полном ряду

1. **Первые две недели января** - аномально высокая активность, связанная с послепраздничными промо-кампаниями. Среднее число покупок в этот период на 30..40% выше, чем в основном окне.
2. **Период с середины января до конца сентября** - основное стабильное окно с медленным трендом и недельной сезонностью. На нём проводится большая часть экспериментов.
3. **Октябрь** - повторное повышение уровня, связанное с предновогодними промо.

Так как данных за прошлые года у нас, анализировать окна с сильно скачущей интенсивностью сложно. Основное окно для экспериментов фиксировано как 2025-01-15..2025-09-30, чтобы исключить новогодний всплеск из `train`-данных и обеспечить стационарность фоновых характеристик. Внутри этого окна также наблюдается недельная сезонность: будни и выходные различаются по среднему уровню `to_ord` примерно на 10%. Эту сезонность нужно будет учесть при построении бейзлайна.

3.3 Гетерогенность пользователей

Если в среднем по датасету $mean(to_ord) \approx 0.10$, то на уровне отдельного пользователя картина может быть сильно иной. Чтобы понять, насколько активность одного пользователя предсказуема через активность того же пользователя в другом периоде, мы построили облако суммарного числа покупок на `train` против `test` для каждого пользователя (рис. 3).

Корреляция Пирсона между `train` и `test` суммами составляет $\sim 0.75..0.80$. Это означает, что значительная часть будущей активности пользователя действительно предсказуема через его исторические суммы - это и есть основной сигнал для Personalized GR. Нобольшая часть дисперсии все еще остаются необъяснёнными за счёт изменения паттерна пользователя во времени, шума и редких всплесков.

В терминах модели сильное различие в поведении пользователей выражается в том, что разброс по логарифму среднего темпа $\log(\mu_u)$ между пользователями составляет 2-3 порядка. Без персонализации модель неизбежно сильно недооценивает активных пользователей и переоценивает неактивных.




Figure 3: Активность пользователей: train vs test

Для иллюстрации структуры данных на уровне одного пользователя - пользователь 612605, активный (321 покупка на train) - показаны его дневные счётчики по трём каналам воронки на рис. 4.

На каждой панели видна экспоненциальная воронка: `searches` (mean 9.8 событий/день для этого пользователя) $\rightarrow$ `to_cart` (5.2) $\rightarrow$ `to_ord` (1.6). Активность нерегулярна - серии активных дней чередуются с периодами относительного затишья. Именно эту структуру self-excitation призван моделировать Hawkes.




Figure 4: Счётчики пользователя 612605 по 3 каналам

3.4 Корреляции каналов и выбор признаков для Hawkes

Матрица корреляций пяти исходных счётчиков показана на рис. 5.

Каналы `search_to_cart` и `search_to_ord` сильно скоррелированы с целевыми `to_cart` и `to_ord` (Пирсон $r > 0.9$), поэтому их включение в Hawkes-states привело бы к коллинеарности фичей и нестабильности оценок α . По итогам этого анализа в основной части работы мы оставляем три независимых канала: `searches`, `to_cart`, `to_ord`. Этого достаточно для содержательного cross-channel анализа и не приводит к мультиколлинеарности.

Корреляции между оставшимися тремя каналами умеренные ($r \approx 0.3..0.5$), что и должно быть для каналов воронки: события вышестоящих этапов (`searches`) частично, но не полностью предсказывают события нижестоящих (`to_ord`).




Figure 5: Корреляция исходных каналов

3.5 Метрика качества: per-observation Poisson NLL и saturated floor

Основная скоринговая метрика - средний негативный log-likelihood Пуассоновской модели на одну строку датасета:

$$\text{NLL} = \frac{1}{N} \sum_{u,t} \left[\lambda_{u,t} - y_{u,t} \log \lambda_{u,t} + \log y_{u,t}! \right].$$

Чем меньше - тем лучше. Метрика согласована с самой моделью наблюдения и поэтому используется как *primary criterion* при сравнении моделей. Дополнительно для диагностики и сопоставимости с регрессионными моделями (бустинг) используются MAE и RMSE.

Существует теоретический минимум NLL, недостижимый никакой Пуассоновской моделью: **saturated Poisson floor**, получаемый подстановкой $\lambda_i = y_i$ в каждой строке. Действительно, при фиксированном y функция $\lambda \rightarrow \log p(y | \lambda)$ достигает максимума при $\lambda = y$, поэтому

$$\text{LL}_{\text{sat}} = \sum_i \left(y_i \log y_i - y_i - \log(y_i!) \right),$$

с договорённостью $0 \log 0 := 0$. На нашем test-окне ($N \approx 513K$ строк) **saturated floor** $\text{NLL}_{\text{sat}} \approx 0.0862$. Это абсолютный нижний предел: разница между лучшей нашей моделью и этим floor'ом - это та часть *aleatoric uncertainty*, которую никаким Пуассоновским предсказанием закрыть нельзя.

Связь saturated floor'a с deviance даёт удобный способ оценивать его из уже обученной модели: $\text{NLL}_{\{\text{model}\}} - \text{NLL}_{\{\text{sat}\}} = \text{mean Deviance} / 2$. Мы используем это соотношение в коде для проверки численной согласованности разных экспериментов.

4 Часть I. Бейзлайн и Хоукс-надстройка на полном train-test

В этой части мы поэтапно строим модель интенсивности $\lambda_{u,t}$. Сначала собираем сильный пуассоновский бейзлайн и обосновываем, какой именно его вариант лучше всего подходит как основа для Хоукс-надстройки. Затем строим саму Хоукс-надстройку и измеряем её вклад. Отдельно рассматриваем бустинг как control-модель, дающую верхнюю планку качества. В конце сводим все полученные модели в единую лестницу и сравниваем по нескольким метрикам. Все эксперименты этой части - на основном протоколе: train 207d, test 52d.

4.1 Постановка: зачем нужен сильный бейзлайн

Напомним постановку из раздела 1.2: в дискретной форме интенсивность раскладывается на бейзлайн и Хоукс-надстройку,

$$\lambda_{u,t} = \underbrace{\mu_{u,t}}_{\text{бейзлайн}} + \underbrace{\sum_j \alpha_j \cdot z_{u,j,t}}_{\text{Хоукс-надстройка}}.$$

Чтобы честно измерить вклад Хоукс-части, нужен максимально сильный бейзлайн $\mu_{u,t}$. Иначе любое улучшение от Хоукс-надстройки рискует объясняться тем, что бейзлайн просто плохо ловит ту часть сигнала, которую сами события могли бы объяснить и без явной self-excitation структуры. Поэтому в Части I сначала строим бейзлайн поэтапно - от простейшего «единая константа» до Personalized Gamma-Poisson с байесовской регуляризацией per-user множителя, - и только после этого добавляем над ним Хоукс-надстройку.

4.2 Построение бейзлайна

Бейзлайн строится поэтапно - сначала несколько простых уровней без персонализации, потом полноценная пользовательская модель:

1. **Global Poisson** - единая константа $\bar{\lambda}$ на весь датасет. Самая простая модель; даёт точку отсчёта.
2. **Rolling Poisson** - скользящее среднее дневного уровня по предыдущим дням. Добавляет учёт глобального тренда без персонализации.
3. **Rolling Seasonal Poisson** - Rolling с поправкой на день недели. Учитывает недельную сезонность (будни vs выходные).
4. **Personalized Gamma-Poisson** - переход от общего дневного профиля к модели с индивидуальным множителем μ_u для каждого пользователя. Эта модель станет финальным бейзлайном для Хоукс-надстройки.

На нашем протоколе первые три модели различаются между собой слабо (test NLL 0.4608 $\rightarrow$ 0.4576 $\rightarrow$ 0.4576): разброс активности между пользователями кратно превышает изменчивость дневного среднего и недельной сезонности. Большой шаг - это переход к персонализации, дающий test NLL 0.4096 (выигрыш +24K в LL над Global

Poisson). Ниже подробно разбираем именно Personalized GP как опорный бейзлайн для всех Хоукс-моделей.

Идея персонализации. Дневной профиль b_t из Rolling Seasonal даёт хорошее общее представление об уровне активности по когорте, но не отличает активного пользователя от неактивного. Естественный способ это исправить - домножить общий профиль на индивидуальный коэффициент μ_u :

$$\lambda_{u,t} = \mu_u \cdot b_t.$$

Если бы у каждого пользователя было много данных, μ_u можно было бы оценить простым MLE: $\hat{\mu}_u = Y_u / E_u$, где $Y_u = \sum_t y_{u,t}$ - суммарное число покупок пользователя на train, а $E_u = \sum_t b_t$ - суммарная экспозиция. Но в нашей задаче для большинства пользователей Y_u маленькое (0-2 покупки на train), и MLE-оценка получается крайне неустойчивой: один лишний наблюденный день меняет $\hat{\mu}_u$ в разы. В крайнем случае при $Y_u = 0$ MLE даёт $\hat{\mu}_u = 0$, что приводит к нулевому прогнозу интенсивности и взрыву NLL на любом ненулевом дне теста.

Поэтому персонализацию в чистом виде применять нельзя - нужна регуляризация: малоактивные пользователи, про которых известно мало, должны автоматически подтягиваться к когортному уровню, а активные с достаточным количеством данных - оставаться близко к своей MLE-оценке.

Полный байесовский вывод. Модель достаточно простая, чтобы вместо явного штрафа провести регуляризацию через полный байесовский вывод. Кладём на μ_u Gamma-prior со средним ≈ 1 - то есть выражаем априорное представление о том, что средний пользователь имеет множитель около единицы:

$$y_{u,t} \mid \mu_u \sim \text{Poisson}(\mu_u \cdot b_t), \quad \mu_u \sim \text{Gamma}(\alpha, \beta).$$

Благодаря сопряжённости Gamma и Poisson posterior μ_u тоже распределён по Gamma и выписывается в замкнутой форме:

$$\mu_u \mid Y_u, E_u \sim \text{Gamma}(\alpha + Y_u, \beta + E_u).$$

В качестве точечной оценки берём posterior mean:

$$\hat{\mu}_u^{\text{EB}} = \frac{\alpha + Y_u}{\beta + E_u}.$$

В этом выражении видно, как байесовский вывод сам решает задачу регуляризации. Для пользователя, про которого мало данных ($Y_u \approx 0$, E_u маленькое), оценка сводится к $\alpha/\beta \approx 1$ - то есть к среднему по когорте. Для активного пользователя с большим Y_u влияние prior'a становится пренебрежимо малым, и $\hat{\mu}_u^{\text{EB}} \rightarrow Y_u / E_u$, то есть к обычному MLE. Никакого дополнительного гиперпараметра «силы регуляризации» здесь нет - баланс между prior'ом и данными выставляется автоматически в зависимости от того, сколько информации есть про конкретного пользователя.

Оценка гиперпараметров. Параметры (α, β) prior'a оцениваются эмпирически - по marginal MLE по всем $\sim 10K$ пользователям одновременно (Empirical Bayes). Интегрируя μ_u , получаем маргинальное распределение (Y_u, E_u) - отрицательное биномиальное, и минимизируем суммарный $-\log p(Y_u, E_u \mid \alpha, \beta)$ по (α, β) методом L-BFGS-B. На нашем датасете это даёт $(\alpha, \beta) \approx (0.88, 0.88)$ - то есть prior со средним ≈ 1 , что согласуется с интерпретацией «средний пользователь имеет множитель около единицы».

Без байесовской регуляризации (чистая MLE с обрезкой $\mu_u = 0$ при $Y_u = 0$) test NLL на полном 52d-test составляет 0.4650. Полный байесовский вывод даёт 0.4096 - выигрыш порядка +24К в LL. Это и есть основное улучшение на пути к опорному бейзлайну.

Анализ выигрыша на уровне отдельных пользователей через **per-user delta-LL** даёт следующую картину (рис. 6):




Figure 6: Per-user delta-LL: Rolling Seasonal $\rightarrow$ Personalized

Распределение $LL = LL_{\{PersGP\}} - LL_{\{RS\}}$ по пользователям сильно неоднородно:

- `share(personalized > rolling seasonal) = 66%` - две трети пользователей выигрывают от персонализации.
- Юзеры с 0..2 покупками выигрывают почти всегда (87..94%) - для них Personalized GP правильно сдвигает прогноз вниз от среднего по когорте.
- Бакет 6..10 покупок - наоборот, проигрывает (18%): на этих пользователях регуляризация ещё ощутимо тянет к когортному среднему, и чистая MLE сработала бы лучше.
- Активные с 11+ снова выигрывают, потому что $\hat{\mu}_u^{EB}$ на них почти не отличается от MLE.

Это структурное замечание важно для интерпретации Хоукс-результатов: Хоукс-надстройка будет работать поверх уже регуляризованного персонализированного бейзлайна и сможет компенсировать чрезмерную регуляризацию на активной части когорты.

4.3 Scaled-baseline Hawkes на персонализированной базе

Над Personalized Gamma-Poisson бейзлайном мы строим **Scaled-baseline Hawkes** - модель с фиксированной персонализированной базой и pooled Хоукс-надстройкой:

$$\lambda_{u,t} = c \cdot \mu_u^{EB} \cdot b_t + \sum_{j,m} \alpha_{j,m} \cdot z_{u,j,m,t},$$

где c - глобальный масштаб базы (один скаляр на всю когорту), а $z_{\{u,j,m,t\}}$ - Hawkes-state с полураспадом m для фичи j . В основной реализации мы используем 5 фичей $\times$ 2 полураспада (1, 3) дня, что даёт 10 параметров α и один скаляр c - итого 11 обучаемых параметров плюс per-user multiplier'ы ($\approx 10K$) из EB-шага.

Обучение двухступенчатое (staged):

1. **EB-шаг** (наследуется из бейзлайна): из Personalized GP получены μ_u^{EB} , (α, β) и b_t . На этом шаге per-user multiplier'ы зафиксированы.
2. **Хоукс-шаг**: численная оптимизация (c, α) методом L-BFGS-B с ограничением $\alpha \geq 0$. Loss - Пуассоновский негативный log-likelihood с мягкой L2-регуляризацией:

$$\mathcal{L}(c, \alpha) = -\log p(y | c\lambda_{base} + X\alpha) + \lambda_\alpha \|\alpha\|_2^2 + \lambda_c (c - 1)^2.$$

Ограничением гарантируют, что Хоукс-надстройка не может стать отрицательной (что нарушило бы Пуассоновскую интерпретацию $\lambda \geq 0$). На каждой итерации L-BFGS-B градиент по (c, α) считается аналитически из chain rule, что делает фит быстрым: на 11 параметрах и $\sim 2M$ строк сходимость достигается за $\sim 100..300$ итераций (~ 30 секунд на CPU).

На главном 207d-train Scaled Hawkes даёт test NLL 0.3958 против 0.4096 у Pers GP - улучшение +7K в LL, или -0.014 в NLL. Обученные параметры: $\hat{c} \approx 0.83$, $\|\alpha\|_2 \approx 0.016$. Тот факт, что $c < 1$, говорит о том, что оптимизатор слегка уменьшает фоновую часть, компенсируя её Хоукс-надстройкой. Это первый намёк на то, что между $c \cdot \mu_u$ и Hawkes-states существует trade-off, к которому мы вернёмся в части III.

Обученная матрица $\alpha[feature \times half - life]$ визуализируется на рис. 7. Основной вклад приходится на `to_ord` (`hl=3`) - наибольший положительный коэффициент, отражающий, что недавняя покупка действительно повышает интенсивность следующей покупки в течение 3 дней. Также видны положительные α для `searches` и `to_cart` на масштабе 1 день, что соответствует короткой воронке `search` $\rightarrow$ `cart` $\rightarrow$ `order` в пределах одной-двух сессий пользователя.

Анализ per-user delta-LL (рис. 8) показывает, что Хоукс-надстройка даёт выигрыш у 63.4% пользователей. В отличие от перехода к персонализации, выигрыш распределён более равномерно по всем бакетам активности (54..80% пользователей выигрывают в каждом бакете). Это говорит о том, что Хоукс-сигнал работает поверх уже выровненного персонализированного бейзлайна и не страдает от перекосов регуляризации.

Mean / median delta-LL: +0.71 / +0.16 на пользователя. Это значит, что среднее улучшение скромное, но устойчивое - нет хвоста пользователей, на которых Hawkes резко проигрывает бейзлайну. Это критичное практическое свойство: модель надёжна на всей когорте.

Регуляризация и выбор полураспадов. Для модели на 11 параметрах с $\sim 2M$ строк train regularization-сетка $(\lambda_\alpha, \lambda_c) \in \{0, 0.01, 0.1, 1, 10, 100\}^2$ показывает, что результат




Figure 7: Тепловая карта Хоукс-коэффициентов: feature $\times$ half-life (Scaled Hawkes)

не зависит от регуляризации в широком диапазоне: размах test NLL по всей сетке составляет менее 0.0005. Это согласуется с практическим правилом, что при $(n_{\text{obs}} / n_{\text{params}}) > 10^5$ явная регуляризация почти не влияет на оптимум - данных достаточно, чтобы оценить параметры с малой дисперсией без помощи prior'a.

Выбор полураспадов - отдельный методический вопрос. Мы тестировали значения $\tau \in \{0.5, 1, 2, 3, 5, 7\}$ дня в комбинации с разным числом параллельных ядер. Главные наблюдения:

- Один полураспад $\tau = 1$ день даёт самый простой и быстрый фит, но теряет недельный «хвост» активности.
- Комбинация (1, 3) дня даёт оптимум по test NLL и сохраняет интерпретируемость двух разделённых масштабов памяти: «немедленный» (сегодня $\rightarrow$ завтра) и «среднесрочный» (3-дневная сессия).
- Дополнительный третий полураспад $\tau = 7$ дней не улучшает скор: его профиль NLL почти плоский. Это значит, что longer-term память уже захвачена бейзлайном $b_t \cdot \mu_u$ через rolling-агрегацию.
- Полураспады меньше суток ($\tau < 1$) теряют смысл для дневной агрегации: они не отличают «сегодня» от «вчера».

В дальнейшем в работе используется конфигурация (1, 3) дня для всех Хоукс-моделей.




Figure 8: Per-user delta-LL: Personalized $\rightarrow$ Scaled Hawkes

4.4 Joint Hawkes как альтернативная параметризация

Рядом со Scaled-baseline Hawkes мы вводим вторую Хоукс-параметризацию - **Joint Hawkes**, где per-user множители λ_u и коэффициенты α обучаются **совместно** напрямую через MLE с явной L2-регуляризацией:

$$\lambda_{u,t} = \lambda_u \cdot b_t + \alpha^\top z_{u,t}, \quad \mathcal{L} = \text{NLL}(y, \lambda) + \lambda_{\ell_2} \sum_u (\lambda_u - 1)^2 + \lambda_\alpha \|\alpha\|_2^2.$$

Главные отличия от Scaled-baseline:

- **Одностадийное обучение** - без отдельного EB-шага. Empirical-Bayes prior на μ_u заменён явным L2-prior'ом $(\lambda_u - 1)^2$, и оптимизатор учитывает его одновременно с Хоукс-частью.
- λ_u **обучается напрямую**, а не наследуется зафиксированным из бейзлайна. Это даёт оптимизатору свободу «перекинуть» массу интенсивности между λ_u и Хоукс-вкладом - Scaled-baseline такой возможности не имеет, потому что μ_u^{EB} зафиксирован.

Обучение - L-BFGS-B по $(n_{\text{users}} + n_\alpha) \approx 10010$ параметрам; благодаря разреженности градиента сходится за $\sim 400 \dots 600$ итераций ($\sim 60 \dots 120$ секунд на CPU). По умолчанию фиксируем $\lambda_{\ell_2} = 1$ как «активный prior».

На главном 207d-train Joint Hawkes даёт почти то же качество, что и Scaled-baseline (test NLL 0.3951 vs 0.3958) - по NLL модели на полном объёме данных практически неотличимы. Но **структура регуляризации у них принципиально разная**, и за счёт этого на коротких train-окнах они выучивают разные закономерности и приходят

к разным точкам в пространстве параметров. Это явление детально разбираем в Части II.

4.5 Бустинг и feature engineering

Чтобы сравнение Хоукс-моделей с бустингом было объективным, бустинг мы тоже старались максимально вытянуть. Основной рычаг улучшения оказался со стороны **feature engineering**: из 5 исходных поведенческих счётчиков (`searches`, `cat_to_cart`, `cat_to_ord`, `to_cart`, `to_ord`) и нескольких производных каналов мы построили **141 фичу**, покрывающую историю, тренды, ЕМА, recency и funnel-ratio. Конкретный набор признаков можно сгруппировать:

- **Календарные (3)**: `dow`, `days_seen`, `week_idx`.
- **History по каждому source-каналу** ($14 \times 8 = 112$): `*_yesterday`, `*_sum3`, `*_sum7`, `*_mean7`, `*_active_days7`, `*_exp3`, `*_last_active`, `*_days_since_last_active`.
- **Агрегаты по заказам и активности**: `orders_hist_mean`, `carts_hist_mean`, `any_activity_sum7`, `any_activity_mean7` и т.п.
- **ЕМА**: `to_ord_ewm7`, `to_ord_ewm28`, `to_ord_ewm_gap_7_28`, `to_cart_ewm7`, `to_cart_ewm28`, `any_activity_ewm7`, `any_activity_ewm28`.
- **Recency и funnel-ratio**: `days_since_last_*`, `ord_per_cart_7`, `search_to_cart_rate_7`, `search_to_ord_rate_7`, `cat_to_cart_rate_7`, `cat_to_ord_rate_7`.

В качестве модели используем `HistGradientBoostingRegressor` с `Poisson loss`. Финальные гиперпараметры: `max_iter=200`, `max_depth=5`, `learning_rate=0.05`, `min_samples_leaf=40`, early stopping по held-out fraction. Со стороны гиперпараметров мы провели несколько точечных экспериментов (вариации глубины, learning rate, числа итераций), но заметного отклика по NLL они не дали - в итоге зафиксировали усреднённо-разумную конфигурацию без агрессивного тюнинга.

Test NLL бустинга - 0.3881, что лучше Scaled-baseline Hawkes (0.3958). Выигрыш составляет +3К..7К в LL. Это означает две вещи. Во-первых, GBDT действительно ловит дополнительный сигнал, которого нет в Hawkes - главным образом нелинейные взаимодействия между фичами recency и активностью. Во-вторых, его абсолютная улучшайка относительно Hawkes мала по сравнению с разрывом между Hawkes и теоретическим saturated floor (0.0862): большая часть оставшегося потенциала - это внутренний шум данных.

В работе GBDT отмечается отдельным цветом - как **reference point**, дающий верхнюю планку качества. Цель - оценить, на каком расстоянии от этой планки находятся интерпретируемые Хоукс-модели.

4.6 Итоговая лестница моделей

Соберём все рассмотренные модели в единую сводную картину. Получается лестница из шести вероятностных моделей плюс GBDT и теоретический saturated floor:

1. **Global Poisson** - единая константа $\bar{\lambda}$ на весь датасет.

2. **Rolling Poisson** - скользящее среднее дневного уровня, без персонализации.
3. **Rolling Seasonal Poisson** - с поправкой на день недели.
4. **Personalized Gamma-Poisson** - персонализация множителем μ_u на предыдущую модель через Байесовский вывод.
5. **Scaled-baseline Hawkes** - Personalized GP с Хоукс-надстройкой.
6. **Joint Hawkes** - совместная оптимизация λ_u и α напрямую через MLE с L2-prior'ом (см. подсекцию выше).
7. **GBDT** - control-модель на расширенном feature-engineering'e (см. предыдущую подсекцию).

Каждый следующий уровень включает в себя структуру предыдущего и добавляет один концептуальный шаг.

Главный вывод: самый крупный единичный шаг - переход к **персонализации** (Gamma-Poisson, -0.0480 в NLL). Все четыре «не персонализированных» бейзлайна на полной кривой почти не отличаются друг от друга, поскольку разброс между пользователями кратно превышает изменчивость во времени. Следующий заметный шаг - Хоукс-надстройка (-0.0138 в NLL). Joint Hawkes даёт почти то же значение, что и Scaled-baseline, отличаясь от него на -0.0007 в NLL - это уже на уровне численного шума. GBDT снимает ещё -0.0070 в NLL, занимая верхнюю планку.

Численная таблица:

Ступень	Модель	Test LL	NLL/n	Δ vs предыдущая (NLL)
1	Global Poisson	-236458	0.4608	-
2	Rolling Poisson	-234805	0.4576	-0.0032
3	Rolling Seasonal	-234782	0.4576	-0.0000
4	Personalized Gamma-Poisson	-210167	0.4096	-0.0480
5	Scaled-baseline Hawkes	-203093	0.3958	-0.0138
6	Joint Hawkes ($\lambda_u + \alpha$)	-202721	0.3951	-0.0007
7	GBDT (experimental)	-199154	0.3881	-0.0070
-	Saturated Poisson floor	-44216	0.0862	-

Доля закрытого зазора между Global Poisson и saturated floor'ом, накопленная к Joint Hawkes, составляет ~18%; до GBDT - ~19%. Остаточные ~80% - это внутренний шум данных, который не может быть закрыт никаким Пуассоновским предсказанием на текущих признаках.

Сводная картина моделей по per-observation NLL и LL/RMSE приведена на рис. 9 и 10.

Видно, что:

- Крупный шаг по NLL даёт переход к персонализации.
- Хоукс-надстройка добавляет ещё стабильный шаг порядка 0.014 в NLL.
- Между Scaled-baseline и Joint Hawkes разница ничтожна (0.0007 в NLL).




Figure 9: Per-observation NLL: лестница моделей




Figure 10: Test LL и RMSE по моделям

- GBDT обходит все вероятностные модели, но без интерпретируемой структуры.

LL-чарт повторяет ту же лестницу в абсолютных числах: переход к персонализации даёт скачок порядка +24К в LL, Хоукс-надстройка - ещё +7К, GBDT улучшает Joint Hawkes ещё на +3.6К. RMSE даёт более согласованную с NLL картину, монотонно убывая от бейзлайна к Hawkes (0.655 → 0.627); GBDT практически совпадает с Joint Hawkes по RMSE (0.6297 vs 0.6291).

Интересный диагностический график - scatter обученных per-user multiplier'ов: m_u из Scaled-baseline Hawkes (где $m_u = c \cdot \mu_u^{EB}$) против m_u из Joint Hawkes (где $m_u = \lambda_u$ напрямую).

Структурные эффекты:

- **Средние значения** (красный крест): $m_{staged} \approx 0.823$, $m_{joint} \approx 0.649$. Joint в среднем занижает множитель сильнее, компенсируя это **примерно в 2 раза большим** $\|\alpha\|_2$ (0.0324 vs 0.0161).
- **Корреляция** $\text{corr}(m_{staged}, m_{joint}) = 0.85$ - высокая, но не единица: модели договариваются о том, кто более активный, но конкретные значения отличаются.




Figure 11: Per-user m_u : Scaled-baseline vs Joint Hawkes

- **Левый хвост** (юзеры с малым числом покупок) лежит **ниже диагонали**: для них Joint без явного EB-prior'a отпускает λ_u в зону ≈ 0 , тогда как EB-shrunk база умножается на $c \approx 0.83$.
- **Активные пользователи** (правый хвост) тоже зачастую ниже диагонали: joint-фит снижает per-user multiplier, оставляя место большой Хоукс-надстройке.

Несмотря на эти разные декомпозиции, итоговый test NLL обеих моделей практически совпадает. Это и есть тот самый $c - \alpha$ **trade-off**: разные оценки (m_u, α) дают почти одинаковую общую интенсивность. На уровне population-NLL модели неотличимы; на уровне внутренних параметров - существенно разные. Это наблюдение играет центральную роль в части III, где мы разворачиваем его в полноценный анализ identifiability через profile likelihood.

5 Часть II. Поведение моделей на коротких train-окнах

Все результаты Части I получены на 207-дневном train. Возникает естественный вопрос: насколько эти выводы устойчивы к выбору train-окна? В промышленных задачах часто доступны только короткие истории (14..30 дней - например, в задачах быстрого онбординга новых сегментов или анализа А/В-эксперимента), и важно понять, какая параметризация Hawkes выживает на таких окнах.

5.1 Blockwise CV: 21-дневные блоки

Первый эксперимент - blockwise cross-validation с непересекающимися 21-дневными блоками. Анализируемый период 2025-01-15..2025-09-30 бьётся на 13 блоков. В каждом блоке первые 14 дней используются как train, последние 7 - как test. Этот сплит несимметричный: ratio train/test = 2:1, что соответствует характерной задаче коротких А/В-тестов, где данных для обучения мало. На каждом блоке независимо обучаются все шесть моделей лестницы плюс GBDT.




Figure 12: Blockwise CV: per-block NLL

На коротких train (14d) картина меняется по сравнению с главным окном. Несколько ключевых наблюдений:

- **Все «не персонализированные» бейзлайны** (Global, Rolling, Rolling Seasonal) дают практически одинаковый mean NLL ~ 0.404 и большой разброс по блокам (0.34..0.45). Они близки между собой, что и ожидаемо: расчёт rolling-mean на 14 днях не сильно отличается от глобального среднего, а недельная сезонность на 14 днях оценивается шумно.
- **Personalized Gamma-Poisson** даёт mean NLL ~ 0.372 - заметное улучшение, но меньшее, чем на главном train (там было ~ 0.41). Это связано с тем, что на 14 днях EB-prior сильнее доминирует - для большинства пользователей $Y_u \approx 0..2$ покупок, и μ_u^{EB} лишь чуть отклоняется от prior'a.
- **Scaled-baseline Hawkes** даёт практически тот же mean NLL, что и Personalized GP - ~ 0.372 . Это указывает на вырождение, о котором речь дальше.

- **Joint Hawkes** даёт mean NLL ~ 0.363 - лучший среди вероятностных моделей, и заметно лучше Pers GP.
- **GBDT** остаётся лидером по абсолюту с mean NLL ~ 0.345 .

Дисперсия результатов по блокам велика для всех моделей. Это говорит о том, что на 14 днях существенную роль играет случайность выбора окна: блок с новогодним всплеском или без него даёт разные NLL даже у одной и той же модели.

5.2 Вырождение Scaled-baseline Hawkes

Эффект вырождения Scaled-baseline Hawkes на 14d train особенно поучителен. Если посмотреть на обученные параметры на каждом блоке, видна следующая картина:

- $\hat{c} \approx 1.00$ (зажат к prior'у $c = 1$);
- $\|\alpha\|_2 \approx 0$ (все Хоукс-веса прижаты к нулю).

То есть модель **полностью теряет Хоукс-надстройку** и фактически сводится к Personalized GP. На уровне предсказательного качества это и подтверждается: их test NLL практически совпадают.

Причина - коллинеарность. На 14 днях Y_u для большинства пользователей ≤ 2 , и EB-prior тянет μ_u^{EB} к среднему по когорте. Этот средний по когорте Hawkes-state $z_{\{u,j,t\}}$ пропорционален баесовскому уровню активности самого пользователя - то есть тому же сигналу, что $\mu_u^{EB} \cdot b_t$. Линейный регрессор не может различить два почти коллинеарных сигнала и предпочитает оставить ровно один - бейзлайн-часть, поскольку именно её prior подталкивает $c \rightarrow 1$.

Это и есть проявление известного из multivariate Хоукс-литературы эффекта [4]: на малом числе наблюдений диагональные компоненты влияния не идентифицируются и поглощаются фоновой интенсивностью. В нашем случае это происходит не на cross-channel диагонали (мы ещё не в cross-channel постановке), а на «временной» диагонали - между μ_u и self-history $z_{\{u, to_ord, t\}}$ для целевого канала.

Вырождение мотивирует переход к другой форме обучения, которая бы не позволяла Хоукс-надстройке схлопнуться к нулю.

5.3 Joint Hawkes на коротких окнах

Joint Hawkes (определение и обучение разобраны в Части I) построен так, что вместо двухступенчатого EB-prior'a на μ_u использует явную L2-регуляризацию регрессор множителей $(\lambda_u - 1)^2$ напрямую при совместной оптимизации с α . Это отличие, малозаметное на полном train (test NLL практически одинаковый со Scaled-baseline), оказывается решающим на коротких окнах.

Активный L2-prior удерживает λ_u в окрестности единицы: оптимизатор не может «зажать» все λ_u в ноль и переложить весь сигнал на Хоукс-часть (или наоборот). На 14d-train Joint Hawkes **не вырождается**: $\|\alpha\|_2 \approx 0.04..0.05$ на всех n от 15 до 200 дней. То есть Хоукс-надстройка остаётся ненулевой и информативной даже там, где у Scaled-baseline она схлопывается до нуля.

По умолчанию используем $\lambda_{\ell_2} = 1$ как «активный prior». Чувствительность результата к этой константе подробно разбираем в Части III; здесь она фиксирована.

5.4 Train-length scan и crossover'ы

Систематический анализ - sweep по длине train-окна $n \in \{15, 21, 27, 36, 48, 63, 84, 114, 153, 198\}$ дней. На каждом значении n берётся m случайных интервалов из анализируемого периода (с фиксированным seed), и для каждого интервала строится разбиение $2n/3$ train + $n/3$ test. На каждом запуске обучаются все семь моделей. Это позволяет получить distribution test NLL для каждой пары (модель, n) и оценить как mean, так и дисперсию.

Сводный график mean test NLL по моделям от n - рис. 13.




Figure 13: Mean NLL по моделям от длины окна

Виден чёткий crossover между моделями:

- На $n \leq 21$ Joint Hawkes слегка опережает Scaled-baseline и Personalized GP (зазор $\sim 0.02 \dots 0.05$ в NLL). Это та самая зона, где Scaled вырождается, а Joint удерживает Хоукс-сигнал.
- На $n \in [27, 60]$ все три вероятностные модели сходятся в почти одну точку. Это переходная зона: Scaled постепенно начинает «находить» Хоукс-надстройку, но ещё не дотягивает до Joint.
- На $n \geq 100$ Scaled-baseline Hawkes и Joint Hawkes становятся почти одинаковыми и оба обходят Personalized GP на ~ 0.02 в NLL. Это зона «полной информации»: данных достаточно, чтобы любая из двух Хоукс-параметризаций сошлась к одному и тому же оптимуму.

GBDT остаётся лучшим в абсолютном смысле на всех n , но **разрыв уменьшается с ростом n** - на длинных train probabilistic-модели догоняют бустинг. На $n = 198$ день разрыв Joint Hawkes vs GBDT составляет ~ 0.009 в NLL против ~ 0.014 на $n = 15$.

Поведение нормы Хоукс-коэффициентов и среднего per-user multiplier'а от n - рис. 14 и 15.




Figure 14: Норма $\|\alpha\|_2$ по моделям от длины окна




Figure 15: Средний per-user multiplier от длины окна

Здесь хорошо видно вырождение: для Scaled-baseline $\|\alpha\| = 0$ на всех $n \leq 50$ (плоское ноль), и только с $n \approx 80$ норма начинает расти. На $n = 198$ норма достигает ~ 0.012 , что близко к значению ~ 0.016 , полученному на полном 207d-train. У Joint Hawkes $\|\alpha\|$ стабилен ($\sim 0.04 \dots 0.05$) с самого $n = 15$, медленно убывая к ~ 0.037 на больших n . Mean per-user multiplier λ_u у Joint Hawkes держится $\sim 0.65 \dots 0.75$ независимо от n , что согласуется с активной L2-регуляризацией к единице.

Главный вывод этой части: **нет универсально лучшей Хоукс-параметризации**, выбор зависит от длины train. На коротких окнах работает Joint Hawkes с активной регуляризацией, на длинных оба Хоукс-варианта эквивалентны. Для индустриальной практики это означает, что в системе с переменной длиной обучающего окна (например, в continuous learning pipeline) имеет смысл использовать Joint Hawkes как default-вариант: он не теряет качества на длинных train и не вырождается на коротких.

6 Часть III. Структура cross-channel Хоукс-матрицы

В первой части мы рассматривали один target - `to_ord` - и вектор α по нескольким source-каналам. В этой части переходим к **cross-channel постановке**: на каждый из трёх каналов воронки (`searches`, `to_cart`, `to_ord`) подгоняется собственная Хоукс-модель, у которой источниками возбуждения служат **все три канала** (включая сам себя). Получается интерпретируемая матрица $\alpha \in \mathbb{R}^{3 \times 3}$ пар-канальных взаимодействий - диагональ описывает self-excitation каждого канала, off-diagonal - cross-channel влияние.

6.1 Cross-channel постановка и верификация

Для каждой пары (`target`, `source`) Hawkes-state строится с тем же полураспадом 1 день, и оптимизация выполняется отдельно по каждому target'у. Модель для одного target'a:

$$\lambda_{u,t}^{(k)} = c_k \cdot \mu_u^{\text{EB},k} \cdot b_t^{(k)} + \sum_{j=1}^3 \alpha_{kj} \cdot z_{u,j,t},$$

где индекс k пробегает 3 канала. На главном 207d-train у Scaled-baseline Hawkes получается матрица:

target ↓ \ source →	searches	to_cart	to_ord
searches	0.1269	0.0240	0
to_cart	0.0103	0.0713	0
to_ord	0.0030	0.0046	0.0194

Визуально (рис. 16):

Структура воронки видна сразу:

- **Верхне-треугольная часть колонки `to_ord` идентически нулевая**: после покупки нет краткосрочного Хоукс-сигнала на поиск или корзину. Это структурный нуль, который мы интерпретируем как отсутствие «обратного» возбуждения в воронке: купив товар, пользователь не идёт сразу искать ещё.
- **Off-diagonal funnel-связи `searches` → `cart` → `order` различимы** и положительны: например, $\alpha[\text{to_cart} \leftarrow \text{searches}] = 0.010$ и $\alpha[\text{to_ord} \leftarrow \text{to_cart}] = 0.0046$. Это согласуется с физической воронкой: поиск повышает интенсивность добавления в корзину, корзина повышает интенсивность покупки.
- **Self- α** $\alpha[\text{to_ord} \leftarrow \text{to_ord}] = 0.019$ ненулевой, но небольшой. Этот коэффициент окажется главным героем последующих разделов: он плохо идентифицируем на коротких train и сильно зависит от регуляризации.

Прежде чем интерпретировать матрицу подробнее, стоит убедиться, что Хоукс-надстройка вообще полезна для каждого из трёх каналов (для `to_ord` это уже показано в части I, но `searches` и `to_cart` - новые target'ы). Сравнение test NLL Personalized GP без Hawkes vs Scaled Hawkes на трёх каналах - рис. 17.




Figure 16: Cross-channel -матрица на главном train (Scaled-baseline)




Figure 17: Per-channel верификация: Pers GP vs Scaled Hawkes vs GBDT

Хоукс-надстройка улучшает бейзлайн на всех трёх каналах: на **searches** - -6.83% от бейзлайна NLL, на **to_cart** - -4.47%, на **to_ord** - -2.92%. Относительное улучшение монотонно убывает по плотности target'a, что согласуется с интуицией: на разреженном **to_ord** Хоукс-сигнал относительно baseline слабее.

На том же рисунке показан третий bar - GBDT на полном feature-engineering'e (141 фича) для каждого из 3 каналов. Бустинг обгоняет Hawkes на всех трёх каналах ещё на 2.21...2.95% от бейзлайна, давая верхнюю планку. При этом Hawkes закрывает 54...77% **суммарного gap'a** от Pers GP до GBDT - большую часть выжимаемого сигнала, ценой более простой структуры и интерпретируемости. Это та же картина trade-off, что и в части I, теперь воспроизведённая отдельно на каждом канале.

6.2 Чувствительность к регуляризации

Структурно матрица α показывает интерпретируемые свойства, но bootstrap-анализ по 10 случайным 100d-окнам обнаруживает важную нестабильность. Mean $\pm$ std по окнам для Scaled-baseline:

ячейка	mean α	std	CV
searches $\leftarrow$ searches	0.0798	0.0058	7.2%
searches $\leftarrow$ to_cart	0.0168	0.0026	15.5%
to_cart $\leftarrow$ searches	0.0060	0.0009	15.6%
to_cart $\leftarrow$ to_cart	0.0347	0.0034	9.7%
to_ord $\leftarrow$ searches	0.0011	0.0005	47.4%
to_ord $\leftarrow$ to_cart	0.0025	0.0009	36.2%
to_ord $\leftarrow$ to_ord	0.0016	0.0024	148.3%

Off-diagonal funnel-связи стабильны ($CV \leq 16\%$ для частых пар, до 47% для редкого $to_ord \leftarrow searches$), но $\alpha[to_ord \leftarrow to_ord]$ **коллапсирует**: median ≈ 0 , в части окон значение зажимается к нулю. Это - та же история, что и в части II (вырождение Scaled-baseline на коротких train), теперь видимая в cross-channel постановке: EB-prior зажимает per-user multiplier к нулю для редко-активных пользователей, и у оптимизатора нет signal для self- α редкого target'a.

Переход к Joint Hawkes с активной регуляризацией решает эту проблему. На том же bootstrap'e Joint Hawkes с $\lambda_{\ell_2} = 1$ удерживает $\alpha[to_ord \leftarrow to_ord] = 0.038$ с CV 14.7%. Если же отключить регуляризацию ($\lambda_{\ell_2} = 0$), self- α снова коллапсирует до 0.0002 с CV 316%. Сравнение трёх режимов - рис. 18.




Figure 18: Сравнение трёх режимов: Scaled vs Joint($_l2=1$) vs Joint($_l2=0$)

Из этого следует важный вывод: **коэффициенты cross-channel матрицы сильно зависят от регуляризации**, причём особенно сильно - диагональные. Off-diagonal элементы стабильны во всех трёх режимах. При этом регуляризация может быть **структурной** (как между Personalized GP с EB-регуляризацией и Joint Hawkes с L2-prior'ом к единице), либо **численной** (как внутри Joint Hawkes - $\lambda_{\ell_2} = 1$ vs $\lambda_{\ell_2} = 0$). Оба типа эквивалентны по своему влиянию на диагональ.

Чтобы понять, как именно регуляризация перераспределяет внутреннюю структуру модели, проведён sweep по $\lambda_{\ell_2} \in \{0, 0.01, 0.05, 0.1, 0.3, 0.5, 1, 2, 5\}$ на главном 207d-train для каждого из 3 target'ов. Поведение разложения интенсивности на бейзлайн-часть $\lambda_u \cdot b_t$ и Хоукс-часть $\alpha^\top z$ показано на рис. 19.

С ростом λ_{ℓ_2} оптимизатор зажимает λ_u к 1, и часть общей массы интенсивности **перетекает из бейзлайн-части $\lambda_u \cdot b_t$ в Хоукс-надстройку $\alpha^\top z$** - на всех 3 каналах. Сильнее всего на редком to_ord: при $\lambda_{\ell_2} = 0$ базовая часть составляет 0.085 в NLL, при $\lambda_{\ell_2} = 5$ - 0.069, а Хоукс-часть растёт с 0.019 до 0.028. То есть α явно выступает **компенсаторной переменной** относительно зажатия λ_u .

При этом test NLL **почти не меняется** по всей сетке λ_{ℓ_2} (рис. 20):




Figure 19: Trade-off: macca baseline vs Hawkes or _l2




Figure 20: Test NLL or _l2

Размах test NLL: $searches \approx 0.009$, $to_cart \approx 0.005$, $to_ord \approx 0.004$. Это значит, что **разные λ_{ℓ_2} дают существенно разные разложения (λ_u, α) , но почти одинаковое predicted intensity на test**. Модель сверх-параметризована на уровне внутренних параметров, при том что её предсказательное качество устойчиво.

Разрешение α по λ_{ℓ_2} - рис. 21.

Картина характеристическая:

- Колонка to_ord - идентический ноль на всём grid'е (структурный результат).
- Off-diagonal funnel-связи устойчивы ($\pm 2..10\%$ по всему диапазону).
- $\alpha[searches \leftarrow searches]$ устойчив ($\pm 4\%$): $0.133 \rightarrow 0.143$.
- $\alpha[to_cart \leftarrow to_cart]$ умеренно меняется ($\pm 13\%$): $0.081 \rightarrow 0.099$.
- $\alpha[to_ord \leftarrow to_ord]$ **сильно зависит от prior'а** ($+82\%$): $0.030 \rightarrow 0.055$.

Внутренняя структура модели поэтому несимметрична: внедиагональные коэффициенты - это «коэффициенты данных», диагональные - особенно $\alpha[to_ord \leftarrow to_ord]$ - это «коэффициенты prior'а». Этот вывод формализуется в следующем разделе через profile likelihood.




Figure 21: Зависимость от λ_{l2} - 3×3 сетка

6.3 Profile likelihood и асимметрия диагонали/внедиагональных

Чтобы напрямую измерить идентифицируемость каждого коэффициента, мы используем **profile likelihood**. Для каждой пары (target, source):

1. Сначала проводим cold-fit unfixed Joint Hawkes - получаем anchor $(\hat{\lambda}_u, \hat{\alpha})$.
2. Строим pin-grid из 11 точек вокруг unfixed значения: $\text{linspace}(0, \max(0.10, 2 \cdot \hat{\alpha}_{\text{source}}), 11)$.
3. Фиксируем $\alpha[\text{target} \leftarrow \text{source}]$ на каждой точке grid'a; ре-оптимизируем λ_u и оставшиеся 2 коэффициента $\alpha[\text{target}, \cdot]$.
4. Считаем train NLL и test NLL для каждой из 11 точек.

Для устойчивости оптимизации используется warm-start sequential sweep: начинаем с точки grid'a, ближайшей к anchor'у, и постепенно расширяемся вверх и вниз; затем два polish-pass'a с re-anchor на текущий best. Это исключает дискретные скачки в profile NLL из-за плохой инициализации.

Полная картина 3×3 для train NLL приведена на рис. 22, для test NLL - на рис. 23. Топология profile'ей характеризуется тремя группами:

- **Жёсткие коэффициенты** ($\text{rangeNLL} \geq 0.03$): to_ord $\leftarrow$ searches (range test NLL 0.103), searches $\leftarrow$ searches (0.096), to_cart $\leftarrow$ searches (0.031). Здесь данные **реально различают** значения коэффициента - profile NLL имеет ярко выраженный минимум.




Figure 22: Train NLL profile по 9 коэффициентам

- **Плоские коэффициенты** ($rangeNLL \leq 0.005$): вся колонка $\alpha[* \leftarrow to_ord]$ плюс $\alpha[searches \leftarrow to_cart]$ и $\alpha[to_ord \leftarrow to_ord]$ (range 0.002). Данные на эти значения практически не реагируют - profile NLL почти константа.
- **Промежуточные**: $to_ord \leftarrow to_cart$ (0.018), $to_cart \leftarrow to_cart$ (0.015).

Топология не зависит от prior'a: control-эксперимент без регуляризации ($\lambda_{\ell_2} = 0$, $\lambda_{\alpha} = 0$) даёт практически те же range'и (с расхождением во втором-третьем знаке). Это **структурный аргумент**: профили - это свойство геометрии данных, а не выбор регуляризации.

Особенно интересно, что диагональный $\alpha[to_ord \leftarrow to_ord]$ оказался **плоским**, несмотря на то, что в линейном фите получает ненулевое значение ~ 0.03 . Это объясняется теоретически известной проблемой [4, 5]: history-state $z^{(k)}$ диагонального канала имеет среднее

$$\mathbb{E}[z_{u,t}^{(k)}] \propto \lambda_u^{(k)} \cdot b_t,$$

- тот же сигнал, что и бейзлайн-часть $\lambda_u \cdot b_t$. Линейная комбинация двух почти коллинеарных регрессоров создаёт **ridge-подобный «жёлоб»** в **parameter space**: множество значений (λ_u, α_{kk}) даёт почти одинаковую $\hat{\lambda}$. Для внедиагональных коэффициентов $z^{(j)}$ относится к другому каналу, не коллинеарному бейзлайну, и коэффициент идентифицируется устойчиво.

В литературе эта же проблема обсуждается в двух подходах:

- Васру, Bompaire, Gaïffas, Muzy [4] предлагают **separate regularization** для диагональных ($_1$ -штраф) и внедиагональных (trace norm) элементов, именно потому, что диагональ absorbs baseline mass.




Figure 23: Test NLL profile по 9 коэффициентам

- Achab, Bacry, Gaïffas, Mastromatteo, Muzy [5] отказываются от MLE в пользу **integrated cumulants**, чтобы обойти diagonal/baseline non-identifiability на коротких выборках.

В нашей работе мы не используем эти методы напрямую - мы признаём диагональ слабо идентифицируемой и формализуем это через интервалы значений вместо точечной оценки (раздел 6.4).

Структурный смысл наблюдения: в линейной additive Хоукс-форме с непустым бейзлайном неидентифицируемость диагонали - общее свойство, а не артефакт нашей конкретной модели. Это согласуется с тем, что мы видим эмпирически: диагональные элементы дрейфуют под изменением регуляризации, внедиагональные - более стабильны.

Сравнение train и test profile'ей при этом неоднородно по структуре матрицы. Внедиагональные коэффициенты ведут себя стабильно: train и test profiles на них совпадают по топологии и положению минимума - данных хватает, чтобы оценка не была артефактом обучения. Диагональные же коэффициенты ведут себя иначе: на них train и test profiles **различаются заметно**, train склонен показывать более узкий и глубокий минимум, чем test, - то есть на диагонали модель легко переобучается под тренировочный сигнал. Это согласуется с тем выводом, что диагональ слабо идентифицируется на коротких выборках, а её точечная оценка зависит не столько от данных, сколько от регуляризатора.

6.4 Интервалы 10%-gain и финальная матрица

Из плоского profile NLL следует, что точечная оценка $\alpha[i, j]$ для плоских коэффициентов малоинформативна. Корректнее говорить **интервалом**: значение лежит где-то в

широком диапазоне, и модель не различает точки внутри него.

Формализуем это так. Для каждой пары (target, source):

- $PG_NLL(target)$ - test NLL Personalized GP scaler'a (baseline без Hawkes);
- min_NLL - минимум test NLL Joint Hawkes по 11 точкам сетки из раздела 6.3 (без регуляризации, чтобы исключить prior-эффекты);
- $gain = PG_NLL - min_NLL$ - выигрыш Hawkes над baseline;
- $threshold = min_NLL + 0.10 \cdot gain$.

Допустимы такие α , при которых модель сохраняет минимум **90% выигрыша** над baseline. Из 11 точек профиля берётся наибольший contiguous диапазон вокруг argmin, где $test_NLL \leq threshold$. На границах - линейная интерполяция между соседними сеточными точками. α_{lo}, α_{hi} - границы интервала, $\alpha_{mid} = (\alpha_{lo} + \alpha_{hi})/2$.

10%-gain intervals over Personalized GP baseline (threshold = $\min + 0.1 \cdot (PG - \min)$, unregularized fit, $\lambda_{l_2} = 0$)




Figure 24: Интервалы 10%-gain для 9 коэффициентов

Численные результаты:

Три ячейки верхнего треугольника (searches $\leftarrow$ to_cart, searches $\leftarrow$ to_ord, to_cart $\leftarrow$ to_ord) имеют плоские профили с $range \leq 0.003$ в NLL - данные на них не реагируют. По convention воронки эти три коэффициента полагаем структурно нулевыми: содержательно это означает, что в воронке searches $\rightarrow$ cart $\rightarrow$ order обратных краткосрочных эффектов нет.

Финальная матрица midpoint'ов (рис. 25):

Матрица нижнетреугольная по convention funnel, поэтому собственные значения совпадают с диагональю: $|eigvals| = [0.059, 0.095, 0.188]$. Спектральный радиус

target $\leftarrow$ source	α_{lo}	α_{hi}	α_{mid}	width
searches $\leftarrow$ searches	0.115	0.261	0.188	0.146
to_cart $\leftarrow$ searches	0.002	0.048	0.025	0.046
to_cart $\leftarrow$ to_cart	0.047	0.143	0.095	0.096
to_ord $\leftarrow$ searches	0.008	0.014	0.011	0.006
to_ord $\leftarrow$ to_cart	0.000	0.028	0.014	0.028
to_ord $\leftarrow$ to_ord	0.017	0.100	0.059	0.083

awkes interaction matrix (10%-gain midpoints, upper triangle zeroed)
 $\rho(M) = 0.1884$




Figure 25: Финальная Хоукс-матрица midpoint'ов

$\rho(M) = 0.188$ сильно меньше единицы - Хоукс-процесс далёк от explosion-порога и описывает stable multivariate Hawkes.

Для сравнения: спектральный радиус point-mean матрицы от Scaled-baseline ch.12.4 был $\rho(\alpha_{scaled}) \approx 0.082$, от Joint Hawkes с $\lambda_{\ell_2} = 1$ - $\rho \approx 0.107$. То, что финальный midpoint-радиус 0.188 выше - естественное следствие выбора верхней границы 10%-интервала вместо mean'а.

Это **финальный интерпретируемый результат cross-channel анализа**: 6-параметрическая нижнетреугольная матрица, описывающая стабильную self-exciting структуру воронки $searches \rightarrow to_cart \rightarrow to_ord$ с явно нулевыми «обратными» рёбрами. Внутри широких 10%-интервалов это один интерпретируемый midpoint'овый ответ - точечная оценка, к которой можно обращаться в дальнейших задачах (например, при оценке cross-channel эффектов А/В-теста).

target ↓ \ source →	searches	to_cart	to_ord
searches	0.188	0	0
to_cart	0.025	0.095	0
to_ord	0.011	0.014	0.059

6.5 Per-user визуализация работы моделей

Чтобы понять различия Personalized GP и Joint Hawkes на уровне отдельных пользователей, мы строим для четырёх типичных юзеров timeline предсказанной интенсивности с фактическими покупками. Выборка пользователей сделана так:

- **активный** (612605): $Y_{\text{train}} = 321$, $Y_{\text{test}} = 93$. Регулярная высокая активность.
- **малоактивный** (238812): $Y_{\text{train}} = 6$, $Y_{\text{test}} = 2$. Редкие изолированные покупки.
- **Joint Hawkes выигрывает** (676128): $Y_{\text{train}} = 7$, $Y_{\text{test}} = 97$, $LL(\text{JH} - \text{GP}) = +151.7$. Скачок активности к концу окна.
- **Joint Hawkes проигрывает** (47946): $Y_{\text{train}} = 899$, $Y_{\text{test}} = 359$, $LL = -134.8$. Сверхактивный пользователь с большой дневной дисперсией.

Траектории Personalized GP - рис. 26, Joint Hawkes - рис. 27.

У Personalized GP интенсивность практически постоянна для каждого пользователя - модель оценивает один числовой уровень $\mu_u^{EB} \cdot b_t$ и его экстраполирует. Поправка от b_t мала ($\pm 5\%$ внутри недели через Rolling Seasonal). У Joint Hawkes интенсивность **динамическая**: после каждого события $\hat{\lambda}$ экспоненциально подсвечивается и спадает к baseline с полураспадом 1-3 дня. Высота всплесков зависит от обученных α -весов и непосредственно от текущего состояния $\mathbf{z}_{\{u,t\}}$.

Failure-modes двух моделей **дополняют друг друга**:

- На малоактивном пользователе обе модели дают практически одинаковый средний уровень (~ 0.04), и разница $LL \approx 0.05$ пренебрежимо мала.
- На активном пользователе обе модели близки по среднему ($\sim 1.5 \dots 2/\text{день}$), но Joint Hawkes пульсирует, иногда overshoots и теряет немного на test ($LL = -17.5$).
- На пользователе с резким переходом режима (676128, мало покупок на train, всплеск на test) Joint Hawkes значительно выигрывает, потому что подхватывает начало роста через Hawkes-states: интенсивность поднимается до $5 \dots 10$ в дни streak'ов. Pers GP остаётся flat у ~ 0.1 и платит большой NLL за каждый ненулевой день. $LL = +151.7$.
- На сверхактивном пользователе с высокой дневной дисперсией (47946) Joint Hawkes overreacts на крупные одиночные дни (где $y = 30 \dots 45$), и его $\hat{\lambda}$ доходит до 20+, тогда как на следующий день у пользователя часто только $2 \dots 3$ покупки. Pers GP с более консервативным средним уровнем ($\sim 4 \dots 5$) лучше согласуется. $LL = -134.8$.




Figure 26: Personalized GP: traces 4 пользователей

На уровне population-NLL разница между моделями скромная (0.3958 vs 0.3951), но per-user LL распределена сильно неоднородно - ± 150 для отдельных пользователей при mean'e ≈ 0 . Это означает, что с точки зрения общего качества модели почти эквивалентны, но в индивидуальных предсказаниях они существенно различны. Для бизнес-применения (например, ранжирование пользователей по ожидаемой выручке) это может быть важно: одна и та же population-метрика может скрывать разные паттерны ошибок.




Figure 27: Joint Hawkes: traces 4 пользователей

7 Заключение

В работе исследовано применение процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce-сервисе на датасете из ~10К пользователей за ~290 дней. Основные результаты сгруппированы по трём ветвям исследования.

Бейзлайн и Хоукс-надстройка на полном train-test (часть I). Построена последовательность из шести вероятностных моделей с переходом от Global Poisson к Joint Hawkes. Самый крупный единичный шаг по test NLL - переход к Personalized Gamma-Poisson через Empirical Bayes (+24K в LL / -0.048 в NLL). Хоукс-надстройка над персонализированным бейзлайном даёт стабильное улучшение порядка +7K в LL / -0.014 в NLL на каждом из трёх независимых каналов воронки (`searches`, `to_cart`, `to_ord`). Контрольный GBDT на полном feature-engineering'e (141 фича) обходит Hawkes ещё на 2..3% от бейзлайна NLL, занимая верхнюю планку по качеству. При этом Hawkes закрывает 54..77% общего gap'a от Pers GP до GBDT при существенно меньшем числе параметров и сохранённой интерпретируемости. Анализ per-user delta-LL показывает, что Хоукс-надстройка работает равномерно по всем бакедам активности, в отличие от персонализации, которая даёт перекосы на средне-активных пользователях.

Поведение на коротких train-окнах (часть II). На коротких train (14..50 дней) Scaled-baseline Hawkes **вырождается** в Personalized GP: оптимизатор не находит дополнительного сигнала для Хоукс-надстройки из-за коллинеарности EB-shrunk базы и редких target-событий. Joint Hawkes с активной L2-регуляризацией $(\lambda_u - 1)^2$ решает эту проблему: при том же предсказательном качестве на длинных train он не вырождается на коротких. Train-length scan по $n \in [15, 200]$ дней демонстрирует чёткий crossover: на $n \leq 21$ лидирует Joint Hawkes, на $n \in [27, 60]$ все модели сходятся, на $n \geq 100$ оба Хоукс-варианта эквивалентны и оба обходят Personalized GP. Для индустриальной практики это означает, что в системе с переменной длиной окна Joint Hawkes является более безопасным default-выбором.

Структура cross-channel Хоукс-матрицы (часть III). Cross-channel матрица $\alpha \in \mathbb{R}^{3 \times 3}$ имеет интерпретируемую структуру: верхнетреугольные коэффициенты ($\alpha[\text{searches} \leftarrow \text{to_cart}]$, $\alpha[\text{searches} \leftarrow \text{to_ord}]$, $\alpha[\text{to_cart} \leftarrow \text{to_ord}]$) идентически нулевые - отражают отсутствие краткосрочного «обратного» возбуждения в воронке. Off-diagonal funnel-связи `searches` $\rightarrow$ `cart` $\rightarrow$ `order` положительны и идентифицируемы стабильно ($CV \leq 16\%$ в bootstrap по $10 \times 100d$ -окнам). Диагональные коэффициенты - особенно $\alpha[\text{to_ord} \leftarrow \text{to_ord}]$ - обладают принципиальной слабой идентифицируемостью: profile NLL почти плоский на широком диапазоне значений. Это структурное следствие коллинеарности history-state и baseline и согласуется с известными в литературе результатами по multivariate Hawkes [4, 5]. Sweep по силе L2-prior'a $\lambda_{\ell_2} \in [0, 5]$ показывает, что регуляризация существенно перераспределяет массу между бейзлайн-частью $\lambda_u \cdot b_t$ и Хоукс-надстройкой $\alpha^\top z$ (особенно на редком `to_ord`), но **почти не влияет на predicted intensity на test** (range NLL ≤ 0.01). На уровне внутренних параметров модель сверх-параметризована: множество разных (λ_u, α) -решений даёт почти одинаковый скор. После формализации через 10%-gain интервалы получена финальная нижнетреугольная матрица midpoint'ов со спектральным радиусом $\rho(M) = 0.188$, описывающая стабильный multivariate Хоукс-процесс.

Практические выводы. Хоукс-модель в виде Joint Hawkes с активной L2-регуляризацией пригодна для прогноза покупок в задачах с коротким и длинным train; она даёт хороший trade-off между предсказательным качеством и интерпретируемостью; cross-channel матрица α допускает прямую интерпретацию как структуру self-excitation

воронки и может использоваться для анализа эффектов на конкретные каналы (например, при подведении итогов А/В-эксперимента с дополнительной декомпозицией эффекта). Tree-ensemble остаётся лучшим в абсолюте, но без структуры - выбор между Hawkes и GBDT определяется приоритетом интерпретируемости над *scoring*'ом. Per-user визуализация показывает, что даже при близких population-метриках Hawkes и Personalized GP дают существенно разные индивидуальные предсказания, и это нужно учитывать при downstream-применении модели.

Направления дальнейшей работы: расширение feature-set для Hawkes-states (включение более длинных полураспадов, категориальных контекстов или session-level фичей); исследование adaptive-регуляризации диагональных коэффициентов в духе раздельной L1/trace norm [4], или замена MLE на integrated cumulants [5]; применение модели к А/В-тестированию с явным cross-channel разложением эффекта; интеграция Хоукс-надстройки с нейросетевым кодером истории в духе RMTPP [3] или Neural Hawkes [7], как способ объединить интерпретируемость α -матрицы с гибкостью deep representation'ов.

References

- [1] Hawkes A. G. **Spectra of some self-exciting and mutually exciting point processes** // Biometrika. - 1971. - Vol. 58, No. 1. - P. 83-90.
- [2] Bacry E., Mastromatteo I., Muzy J.-F. **Hawkes processes in finance** // Market Microstructure and Liquidity. - 2015. - Vol. 1, No. 1. - 1550005.
- [3] Du N., Dai H., Trivedi R., Upadhyay U., Gomez-Rodriguez M., Song L. **Recurrent marked temporal point processes: Embedding event history to vector** // Proceedings of KDD. - 2016. - P. 1555-1564.
- [4] Bacry E., Bompairé M., Gaïffas S., Muzy J.-F. **Sparse and low-rank multivariate Hawkes processes** // Journal of Machine Learning Research. - 2020. - Vol. 21, No. 50. - P. 1-32.
- [5] Achab M., Bacry E., Gaïffas S., Mastromatteo I., Muzy J.-F. **Uncovering causality from multivariate Hawkes integrated cumulants** // Journal of Machine Learning Research. - 2018. - Vol. 18, No. 192. - P. 1-28.
- [6] Fader P. S., Hardie B. G. S., Lee K. L. **RFM and CLV: Using iso-value curves for customer base analysis** // Journal of Marketing Research. - 2005. - Vol. 42, No. 4. - P. 415-430.
- [7] Mei H., Eisner J. **The neural Hawkes process: A neurally self-modulating multivariate point process** // Advances in Neural Information Processing Systems. - 2017. - Vol. 30. - P. 6754-6764.
- [8] Friedman J. H. **Greedy function approximation: A gradient boosting machine** // The Annals of Statistics. - 2001. - Vol. 29, No. 5. - P. 1189-1232.