

Применимость процессов Хокса для предсказания пользовательской активности в e-commerce

Алексей Мошкин

МКН СПбГУ

Научный руководитель: Николаев Максим Сергеевич

2026

Аннотация

Работа посвящена применению процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce. Прогноз пользовательской активности - важный блок при оценке ценности клиента, планировании коммуникаций с ним и подведении итогов A/B-экспериментов. Точные модели интенсивности позволяют не только улучшать бизнес-метрики, но и интерпретировать структуру пользовательского поведения. А процессы Хокса с экспоненциальным ядром естественно описывают самовозбуждение и кросс-канальное влияние событий и при этом сохраняют легко интерпретируемые параметры, что выгодно отличает их от более сложных моделей машинного обучения, например бустингов.

Актуальность работы обусловлена тем, что в индустриальных задачах с разреженными счётчиками (доля нулей в нашем датасете - 93.7%) интерпретируемость модели особенно важна. В работе мы показываем, что Хоукс-паттерны в данных действительно присутствуют - кросс-канальная воронка восстанавливается как осмысленная структура, - однако из-за разреженности target'a и эффекта «перетока массы» между бейзлайн-частью и Хоукс-надстройкой коэффициенты модели устойчиво проявляются только на достаточно длинных train-окнах. В работе исследуется не только предсказательное качество Хоукс-моделей, но и их сходимость, чувствительность к выбору регуляризации, идентифицируемость коэффициентов и поведение на разных длинах обучающего окна - то есть аспекты, важные для практического применения модели.

В качестве данных используется датасет из 10K пользователей крупного маркетплейса за 290 дней с пятью поведенческими счётчиками (`searches`, `cat_to_cart`, `cat_to_ord`, `to_cart`, `to_ord`). Основной target - число покупок `to_ord` на пару (`user`, `day`). Все эксперименты проводятся на воспроизводимом коде на Python.

Основные результаты: построена иерархия из шести вероятностных моделей с переходом от Global Poisson к Joint Hawkes; на главном 207-дневном train-test разбиении Хоукс-надстройка устойчиво улучшает персонализированный пуассоновский бейзлайн на трёх независимых каналах; восстановлена cross-channel матрица Хоукс-взаимодействий $\alpha \in \mathbb{R}^{3 \times 3}$ для каналов воронки `searches` $\rightarrow$ `to_cart` $\rightarrow$ `to_ord` и оценены доверительные интервалы её коэффициентов. Через ландшафт лосса показано, что диагональные коэффициенты на разреженных каналах слабо идентифицируемы,

что согласуется с известными результатами по многоядерным Хоукс процессам [4, 5]. Так как данные у нас табличные и наблюдений много, ожидаемо верхнюю планку качества дала бустинг-модель, обученная на расширенном feature-engineering'e (построена 141 фича), - но с менее интерпретируемой структурой. Дополнительно проведёно исследование, показывающие, что эффект от Хоукс ядер сильно скоррелирован с настройками базовой интенсивности, за счет этого возможен "переток массы" между Хоукс-частью и базовой интенсивностью без значительной потери качества, из-за чего выбор регуляризации(численной или структурной) очень важен, так как именно он регулирует где осядет масса. Особенно сильно этот эффект проявляется на коротких train-test окнах, где в зависимости от регуляризации веса Хоукс ядер могут полностью обнулиться.

Contents

Аннотация	1
1 Введение	3
1.1 Постановка задачи и актуальность	3
1.2 Процессы Хокса: специфика и применимость к задаче	3
1.3 Цели и задачи работы	4
1.4 Используемые данные	5
2 Обзор литературы	6
3 Разведочный анализ данных и метрика качества	7
3.1 Структура датасета и разреженность	7
3.2 Дневная интенсивность на полном ряду	7
3.3 Гетерогенность пользователей	8
3.4 Корреляции каналов и выбор признаков для Hawkes	10
3.5 Метрика качества: per-observation Poisson NLL и saturated floor	10
4 Часть I. Бейзлайн и Хоукс-надстройка на полном train-test	12
4.1 Постановка: зачем нужен сильный бейзлайн	12
4.2 Построение бейзлайна	12
4.3 Scaled-baseline Hawkes на персонализированной базе	15
4.4 Joint Hawkes как альтернативная параметризация	17
4.5 Бустинг и feature engineering	18
4.6 Итоговая лестница моделей	18
4.7 Декомпозиция интенсивности: Scaled-baseline vs Joint Hawkes	21
5 Часть II. Поведение моделей на коротких train-окнах	22
5.1 Blockwise CV: 21-дневные блоки	22
5.2 Вырождение Scaled-baseline Hawkes	23
5.3 Joint Hawkes на коротких окнах	23
5.4 Train-length scan и crossover'ы	24

6	Часть III. Структура cross-channel Хоукс-матрицы	27
6.1	Cross-channel постановка и верификация	27
6.2	Стабильность коэффициентов: train-окно и регуляризация	29
6.3	Зависимость Хоукс-матрицы Joint Hawkes от коэффициента регуляризации	30
6.4	Profile likelihood и асимметрия диагонали/внедиагональных	31
6.5	Интервалы 10%-gain и финальная матрица	34
6.6	Per-user визуализация работы моделей	36
7	Заключение	39

1 Введение

1.1 Постановка задачи и актуальность

Задача предсказания пользовательской активности - одна из центральных в современном e-commerce. Точная оценка ожидаемого числа покупок `to_ord` на пару (`user`, `day`) может напрямую использоваться в персонализации ранжирования, расчёте CLV и подведении итогов A/B-экспериментов.

С формальной точки зрения мы оцениваем дневную интенсивность $\lambda_{u,t}$ и предполагаем условную Пуассоновскую модель наблюдения:

$$y_{u,t} \mid \lambda_{u,t} \sim \text{Poisson}(\lambda_{u,t}),$$

где $y_{u,t}$ - число покупок пользователя u в день t , а $\lambda_{u,t}$ - наша точечная оценка интенсивности. Задача состоит в предсказании $\lambda_{u,t}$ на отложенную тестовую выборку.

Особенность задачи - крайняя разреженность сигнала: в наших данных среднее число покупок на (`user`, `day`) ≈ 0.10 , а доля нулевых ячеек - 93.7%. Такие данные плохо подходят к классическим регрессионным методам, ориентированным на нормальные ошибки, и требуют явного учёта Пуассоновского распределения наблюдений.

Ещё одна особенность - событийный характер сигнала. Покупки не происходят равномерно во времени: часто наблюдаются «вспышки» активности (пользователь сделал серию заказов за один-два дня) с последующей длительной паузой. Для моделирования такой динамики могут применяться self-exciting процессы, в котором недавние события явно влияют на интенсивность будущих событий, и.

Актуальность работы определяется тремя факторами. Во-первых, индустриальные системы прогноза покупок чаще всего опираются на слабо интерпретируемые модели (GBDT, нейросети), которые дают хороший скор, но не дают понимания структуры пользовательского поведения. Во-вторых, при оценке эффектов A/B-экспериментов важно не только качество прогноза, но и стабильность модели на коротких окнах и интерпретируемость её параметров - здесь GBDT с сотнями признаков становится плохо контролируемым инструментом. В-третьих, процессы Хокса, успешно применявшиеся в финансах [2] и анализе кликовых потоков [3, 7], редко рассматриваются в индустриальном e-commerce как полноценный инструмент - несмотря на то, что их параметры (`per-user multiplier`, матрица α -взаимодействий) допускают прямую бизнес-интерпретацию.

1.2 Процессы Хокса: специфика и применимость к задаче

Процесс Хокса - это самовозбуждающийся точечный процесс, в котором интенсивность будущих событий зависит от истории уже случившихся [1]. В классической непрерывной форме одномерный процесс с экспоненциальным ядром записывается как

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha \cdot \exp(-\beta(t - t_i)),$$

где μ - фоновая интенсивность, α - вес возбуждения, а β - скорость затухания сигнала. Каждое произошедшее событие повышает интенсивность в ближайшем будущем. Свойство "памяти" этого процесса - конечное: после нескольких полураспадов событие фактически перестаёт влиять на текущую интенсивность.

В многомерной форме (K типов событий) ядра становятся матричными:

$$\lambda_k(t) = \mu_k + \sum_{j=1}^K \sum_{t_i^{(j)} < t} \alpha_{kj} \cdot \exp\left(-\beta_{kj}(t - t_i^{(j)})\right).$$

Здесь α_{kj} интерпретируется как «сила влияния события типа j на интенсивность типа k ». Эта матричная структура и есть та самая cross-channel матрица, которая в нашей работе восстанавливается для воронки `searches → to_cart → to_ord`.

В дискретно-дневной форме, удобной для нашей задачи, мы пишем

$$\lambda_{u,t} = \underbrace{\mu_{u,t}}_{\text{baseline}} + \sum_j \alpha_j \cdot z_{u,j,t},$$

где $\mu_{u,t}$ - уверенный бейзлайн пользовательской интенсивности, построим его чуть позже, а $z_{u,j,t}$ - экспоненциально сглаженный счётчик j -ой фичи у пользователя u до дня t :

$$z_{u,j,t} = \sum_{s < t} x_{u,j,s} \cdot \exp\left(-\frac{t-s}{\tau_j}\right),$$

с заданным полураспадом τ_j (в большинстве экспериментов мы используем $\tau \in \{1, 3\}$ дня). Веса α_j оцениваются по обучающей выборке и допускают прямую интерпретацию: положительный α_j означает, что событие фичи j повышает интенсивность будущих покупок этого пользователя.

Применимость процессов Хокса к нашей задаче объясняется следующими свойствами:

1. **Self-excitation естественно описывает воронку покупок.** В e-commerce покупка не происходит «из ниоткуда»: ей часто предшествует серия поисков, просмотров и добавлений в корзину. Hawkes явно моделирует эту короткую память.
2. **Параметры интерпретируемы.** Матрица $\alpha[\text{target} \leftarrow \text{source}]$ показывает, какие каналы и в какой мере возбуждают другие каналы. Это даёт бизнес-понимание, недоступное у GBDT.
3. **Аддитивная декомпозиция бейзлайн + надстройка.** Модель явно разделяет «фоновую активность» пользователя и «короткие всплески от событий», что позволяет независимо изучать обе компоненты.

Платой за интерпретируемость становится более ограниченная функциональная форма: линейная additive комбинация $\lambda_u \cdot b_t + \alpha^\top z$ игнорирует нелинейные взаимодействия признаков, которые GBDT мог бы учесть. Оценка того, насколько много полезной информации при таком упрощении мы теряем - одна из задач работы.

1.3 Цели и задачи работы

Цель работы: исследовать границы применимости процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce, оценить их предсказательное качество и стабильность по сравнению с вероятностным бейзлайном

и бустинговой моделью, а также изучить идентифицируемость и интерпретируемость их коэффициентов.

Задачи работы:

1. Построить иерархию вероятностных моделей, дающую устойчивый бейзлайн для последующей Хоукс-надстройки.
2. Исследовать особенности сходимости коэффициентов Хоукс-моделей: на каком объёме train они стабилизируются и какая параметризация подходит для коротких окон.
3. Восстановить cross-channel матрицу $\alpha[target \leftarrow source]$ для трёх каналов воронки и оценить её устойчивость к выбору train-окна и регуляризации.
4. Сравнить Хоукс-модель с двумя контрольными моделями - статистическим бейзлайном и бустингом на расширенном feature-engineering'e датасете - на нескольких train-test разбиениях.

1.4 Используемые данные

Все эксперименты проводятся на открытом датасете, обезличенно отражающем поведение 10000 случайно выбранных пользователей крупного e-commerce-сервиса за период 2025-01-15..2025-10-31 (290 дней). На каждую пару (user, day) доступны пять поведенческих счётчиков (число событий за день):

- `searches` - пользовательские поиски, mean ≈ 1.20 событий на строку;
- `cat_to_cart` - переходы из категории в корзину;
- `cat_to_ord` - переходы из категории к оформлению заказа;
- `to_cart` - добавления товаров в корзину, mean ≈ 0.37 ;
- `to_ord` - оформленные заказы (target), mean ≈ 0.10 .

Структура данных - длинный pandas DataFrame с ~ 2.87 М строк формы (user_id, event_date, searches, to_cart, to_ord, ...). Все ячейки заполнены явно: даже если пользователь в какой-то день не проявлял активности, в датасете присутствует строка с нулями. Это упрощает построение rolling-агрегатов и Hawkes-states одной свёрткой по каждому пользователю.

2 Обзор литературы

Процессы Хокса как класс самовозбуждающихся точечных процессов введены Хоксом [1] и долгое время применялись преимущественно в сейсмологии и финансах [2]. С развитием современных систем сбора пользовательских данных интерес к ним смещается в сторону анализа кликовых потоков, рекомендательных систем и e-commerce.

Существенная часть современной литературы посвящена нейронным расширениям Хоукс-моделей. Du et al. [3] предложили recurrent marked temporal point processes (RMTPP), в которых дискретная история событий пользователя сжимается рекуррентной сетью в вектор состояния, по которому затем предсказывается интенсивность будущих событий. Mei и Eisner [7] развили эту идею в neural Hawkes process, явно параметризовав интенсивность нейросетью, сохраняющей формальную структуру self-exciting процесса. Эти подходы дают высокое качество, но за счёт интерпретируемости: нейросетевой блок становится чёрным ящиком, и непосредственно «прочитать» матрицу cross-channel влияний из обученной модели нельзя.

Параллельно развиваются классические multivariate Хоукс-модели с акцентом именно на интерпретируемость и идентифицируемость. Bacry, Bompierre, Gaïffas и Muzy [4] показывают, что при оценке коэффициентов многомерного Хоукс-процесса по максимальному правдоподобию имеет смысл регуляризовать диагональные элементы матрицы влияния отдельно от внедиагональных: первые отвечают за «свой» self-excitation канала и часто коллинеарны фоновой интенсивности μ , вторые описывают cross-channel взаимодействия и идентифицируются устойчивее. В нашей работе мы наблюдаем эту же асимметрию эмпирически (см. часть III) и связываем её с тем же механизмом коллинеарности history-state и baseline. Параллельно Achab et al. [5] предложили отказ от MLE в пользу integrated cumulants, чтобы обойти проблему non-identifiability диагональных коэффициентов на коротких выборках; их подход не требует точной формы ядер и масштабируется к большим K через спектральные разложения матриц моментов.

В индустриальном контексте предсказания пользовательской активности классическим инструментом остаются модели семейства Pareto/NBD и Beta-Geometric, восходящие к работам Fader и Hardie [6]. Их центральная идея - Gamma-prior на индивидуальный темп покупок пользователя λ_u , с регуляризацией оценки через Empirical-Bayes posterior. Этот же приём используется нами в Personalized Gamma-Poisson бейзлайне и оказывается основным шагом, дающим крупнейший выигрыш по NLL: при $(\alpha, \beta) \approx (0.88, 0.88)$ модель аккуратно ранжирует пользователей по их «истинному» темпу и обеспечивает устойчивую базу для последующей Хоукс-надстройки.

Наконец, для сравнения с интерпретируемой моделью используются современные бустинговые методы, в первую очередь Gradient Boosting Machines в реализации Friedman [8] и их продвинутые версии (HistGradientBoosting, LightGBM, CatBoost). На широком feature-engineering'e такие модели дают верхнюю планку по качеству, особенно когда сигнал содержит нелинейные взаимодействия признаков, плохо схватываемые линейной additive формой Hawkes. Однако они не дают структурных коэффициентов, сопоставимых с матрицей α Хоукс-процесса, и поэтому используются в работе как control, а не как самостоятельная цель.

3 Разведочный анализ данных и метрика качества

3.1 Структура датасета и разреженность

Панель данных представляет собой плотную таблицу ($\text{user} \times \text{day}$) без пропусков: для каждого из 10K пользователей доступны строки на все 290 дней анализируемого периода (нулевые счётчики записаны явно).

Распределение таргета `to_ord` крайне разреженное. Гистограмма числа покупок на `user-day` ($\log\text{-Y}$) показана на рис. 1.




Figure 1: Распределение числа покупок на `user-day` ($\log\text{-Y}$)

Видны три структурных факта:

- Подавляющее большинство ячеек содержат нули - точнее, 93.7% строк датасета имеют `to_ord = 0`.
- Существует тяжёлый правый хвост: единичные (`user, day`)-пары содержат десяток покупок и больше, при максимуме порядка сотни. Это означает, что распределение `to_ord` имеет крайне тяжелые хвосты.
- При этом среднее по данным ≈ 0.10 - и есть та самая разреженность сигнала.

Эта картина мотивирует две вещи. Во-первых, использовать именно Пуассоновскую модель наблюдения, а не нормальную регрессию - иначе при 93.7% нулей оптимум прогноза вырождается в константу около нуля. Во-вторых, явно учитывать пер-юзерную гетерогенность через какую-то персонализации.

Распределение активности по пользователям тоже крайне неравномерное: 18% самых активных пользователей делают 62% всех покупок. Это в духе классического правила Парето и согласуется с эмпирическими наблюдениями из работ по CLV [6].

3.2 Дневная интенсивность на полном ряду

Агрегированная по дням дневная интенсивность `to_ord` представлена на рис. 2.

На полном ряду выделяются три режима:




Figure 2: Дневная интенсивность `to_ord` на полном ряду

1. **Первые две недели января** - аномально высокая активность, связанная с послепраздничными промо-кампаниями. Среднее число покупок в этот период на 30..40% выше, чем в основном окне.
2. **Период с середины января до конца сентября** - основное стабильное окно с медленным трендом и недельной сезонностью. На нём проводится большая часть экспериментов.
3. **Октябрь** - повторное повышение уровня, связанное с предновогодними промо.

Так как данных за прошлые года у нас, анализировать окна с сильно скачущей интенсивностью сложно. Основное окно для экспериментов фиксировано как 2025-01-15..2025-09-30, чтобы исключить новогодний всплеск из `train`-данных и обеспечить стационарность фоновых характеристик. Внутри этого окна также наблюдается недельная сезонность: будни и выходные различаются по среднему уровню `to_ord` примерно на 10%. Эту сезонность нужно будет учесть при построение бейзлайна.

3.3 Гетерогенность пользователей

Если в среднем по датасету $mean(to_ord) \approx 0.10$, то на уровне отдельного пользователя картина может быть сильно иной. Чтобы понять, насколько активность одного пользователя предсказуема через активность того же пользователя в другом периоде, мы построили облако суммарного числа покупок на `train` против `test` для каждого пользователя (рис. 3).



Figure 3: Активность пользователей: train vs test

Корреляция Пирсона между train и test суммами в log-шкале (в которой и построен график) составляет 0.55; Spearman даёт близкое значение. То есть историческая активность предсказывает будущую заметно, но далеко не идеально - значительная часть дисперсии остаётся за счёт изменения паттерна пользователя во времени, шума и редких всплесков. И возможно изменение паттерна поведения как раз получится объяснить Хоукс-процессами.

Для иллюстрации структуры данных на уровне одного пользователя - пользователь 612605, активный (321 покупка на train) - показаны его дневные счётчики по трём каналам воронки на рис. 4.




Figure 4: Счётчики пользователя 612605 по 3 каналам

Активность нерегулярна - серии активных дней чередуются с периодами относительного затишья. Именно эту структуру self-excitation призван моделировать Hawkes.

3.4 Корреляции каналов и выбор признаков для Hawkes

Матрица корреляций пяти исходных счётчиков показана на рис. 5.




Figure 5: Корреляция исходных каналов

Каналы `search_to_cart` и `search_to_ord` сильно скоррелированы с целевыми `to_cart` и `to_ord` (Пирсон $r > 0.9$), поэтому их включение в `Hawkes-states` привело бы к коллинеарности фичей и нестабильности оценок α . Также в датасете есть каналы `cat_to_cart` и `cat_to_ord`; информации в них мало, их добавление в Хоукс-модели не влияет на качество, зато усложняет анализ, поэтому их мы тоже не включаем. По итогам этого анализа в основной части работы мы оставляем три независимых канала: `searches`, `to_cart`, `to_ord`. Этого достаточно для содержательного cross-channel анализа и не приводит к мультиколлинеарности.

Корреляции между оставшимися тремя каналами умеренные ($r \approx 0.3..0.5$), что и должно быть для каналов воронки: события вышестоящих этапов (`searches`) частично, но не полностью предсказывают события нижестоящих (`to_ord`).

3.5 Метрика качества: per-observation Poisson NLL и saturated floor

Основная скоринговая метрика - средний негативный log-likelihood Пуассоновской модели на одну строку датасета:

$$\text{NLL} = \frac{1}{N} \sum_{u,t} \left[\lambda_{u,t} - y_{u,t} \log \lambda_{u,t} + \log y_{u,t}! \right].$$

Чем меньше - тем лучше. Метрика согласована с самой моделью наблюдения и поэтому используется как *primary criterion* при сравнении моделей. Дополнительно для диагностики и сопоставимости с регрессионными моделями (бустинг) используются MAE и RMSE.

Очевидно, что нулевой NLL никакой Пуассоновской моделью получить нельзя - даже идеальное предсказание $\lambda = y$ в каждой строке даёт ненулевое значение из-за самой формы Пуассоновского правдоподобия. Этот теоретический минимум называют **saturated Poisson floor**; для нашего test-окна ($N \approx 513K$ строк) он равен $NLL_{\text{sat}} \approx 0.0862$. Сам по себе этот floor недостижим: разрыв между ним и нашей лучшей моделью имеет две природы - часть его объясняется ограниченностью самой модели, не извлекающей весь доступный сигнал, а часть - это *aleatoric uncertainty*, шум в данных, который никаким Пуассоновским предсказанием закрыть нельзя.

4 Часть I. Бейзлайн и Хоукс-надстройка на полном train-test

В этой части мы поэтапно строим модель интенсивности $\lambda_{u,t}$. Сначала собираем сильный пуассоновский бейзлайн и обосновываем, какой именно его вариант лучше всего подходит как основа для Хоукс-надстройки. Затем строим саму Хоукс-надстройку и измеряем её вклад. Отдельно рассматриваем бустинг как control-модель, дающую верхнюю планку качества. В конце сводим все полученные модели в единую лестницу и сравниваем по нескольким метрикам. Все эксперименты этой части - на основном протоколе: train 207d, test 52d.

4.1 Постановка: зачем нужен сильный бейзлайн

Напомним постановку из раздела 1.2: в дискретной форме интенсивность раскладывается на бейзлайн и Хоукс-надстройку,

$$\lambda_{u,t} = \underbrace{\mu_{u,t}}_{\text{бейзлайн}} + \underbrace{\sum_j \alpha_j \cdot z_{u,j,t}}_{\text{Хоукс-надстройка}}.$$

Чтобы честно измерить вклад Хоукс-части, нужен максимально сильный бейзлайн $\mu_{u,t}$. Иначе любое улучшение от Хоукс-надстройки рискует объясняться тем, что бейзлайн просто плохо ловит ту часть сигнала, которую сами события могли бы объяснить и без явной self-excitation структуры. Поэтому в Части I сначала строим бейзлайн поэтапно - от простейшего «единая константа» до Personalized Gamma-Poisson с байесовской регуляризацией per-user множителя, - и только после этого добавляем над ним Хоукс-надстройку.

4.2 Построение бейзлайна

Бейзлайн строится поэтапно - сначала несколько простых уровней без персонализации, потом полноценная пользовательская модель:

1. **Global Poisson** - единая константа $\bar{\lambda}$ на весь датасет. Самая простая модель; даёт точку отсчёта.
2. **Rolling Poisson** - скользящее среднее дневного уровня по предыдущим дням. Добавляет учёт глобального тренда без персонализации.
3. **Rolling Seasonal Poisson** - Rolling с поправкой на день недели. Учитывает недельную сезонность (будни vs выходные).
4. **Personalized Gamma-Poisson** - переход от общего дневного профиля к модели с индивидуальным множителем μ_u для каждого пользователя. Эта модель станет финальным бейзлайном для Хоукс-надстройки.

На нашем протоколе первые три модели различаются между собой слабо (test NLL 0.4608 $\rightarrow$ 0.4576 $\rightarrow$ 0.4576): разброс активности между пользователями кратно превышает изменчивость дневного среднего и недельной сезонности. Большой шаг - это переход к персонализации, дающий test NLL 0.4096 (выигрыш -0.051 в NLL над Global

Poisson). Ниже подробно разбираем именно Personalized GP как опорный бейзлайн для всех Хоукс-моделей.

Идея персонализации. Дневной профиль b_t из Rolling Seasonal даёт хорошее общее представление об уровне активности по когорте, но не отличает активного пользователя от неактивного. Естественный способ это исправить - домножить общий профиль на индивидуальный коэффициент μ_u :

$$\lambda_{u,t} = \mu_u \cdot b_t.$$

Если бы у каждого пользователя было много данных, μ_u можно было бы оценить простым MLE: $\hat{\mu}_u = Y_u / E_u$, где $Y_u = \sum_t y_{u,t}$ - суммарное число покупок пользователя на train, а $E_u = \sum_t b_t$ - суммарная экспозиция. Но в нашей задаче для большинства пользователей Y_u маленькое (0-2 покупки на train), и MLE-оценка получается крайне неустойчивой: один лишний наблюденный день меняет $\hat{\mu}_u$ в разы. В крайнем случае при $Y_u = 0$ MLE даёт $\hat{\mu}_u = 0$, что приводит к нулевому прогнозу интенсивности и взрыву NLL на любом ненулевом дне теста.

Поэтому персонализацию в чистом виде применять нельзя - нужна регуляризация: малоактивные пользователи, про которых известно мало, должны автоматически подтягиваться к когортному уровню, а активные с достаточным количеством данных - оставаться близко к своей MLE-оценке.

Полный байесовский вывод. Модель достаточно простая, чтобы вместо явного штрафа провести регуляризацию через полный байесовский вывод. Кладём на μ_u Gamma-prior со средним ≈ 1 - то есть выражаем априорное представление о том, что средний пользователь имеет множитель около единицы:

$$y_{u,t} \mid \mu_u \sim \text{Poisson}(\mu_u \cdot b_t), \quad \mu_u \sim \text{Gamma}(\alpha, \beta).$$

Благодаря сопряжённости Gamma и Poisson posterior μ_u тоже распределён по Gamma и выписывается в замкнутой форме:

$$\mu_u \mid Y_u, E_u \sim \text{Gamma}(\alpha + Y_u, \beta + E_u).$$

В качестве точечной оценки берём posterior mean:

$$\hat{\mu}_u^{\text{EB}} = \frac{\alpha + Y_u}{\beta + E_u}.$$

В этом выражении видно, как байесовский вывод сам решает задачу регуляризации. Для пользователя, про которого мало данных ($Y_u \approx 0$, E_u маленькое), оценка сводится к $\alpha/\beta \approx 1$ - то есть к среднему по когорте. Для активного пользователя с большим Y_u влияние prior'a становится пренебрежимо малым, и $\hat{\mu}_u^{\text{EB}} \rightarrow Y_u / E_u$, то есть к обычному MLE. Никакого дополнительного гиперпараметра «силы регуляризации» здесь нет - баланс между prior'ом и данными выставляется автоматически в зависимости от того, сколько информации есть про конкретного пользователя.

Оценка гиперпараметров. Параметры (α, β) prior'a оцениваются эмпирически - по marginal MLE по всем $\sim 10K$ пользователям одновременно (Empirical Bayes). Интегрируя μ_u , получаем маргинальное распределение (Y_u, E_u) - отрицательное биномиальное, и минимизируем суммарный $-\log p(Y_u, E_u \mid \alpha, \beta)$ по (α, β) методом L-BFGS-B. На нашем датасете это даёт $(\alpha, \beta) \approx (0.88, 0.88)$ - то есть prior со средним

≈ 1 , что согласуется с интерпретацией «средний пользователь имеет множитель около единицы».

Без байесовской регуляризации (чистая MLE с обрезкой $\mu_u = 0$ при $Y_u = 0$) test NLL на полном 52d-test составляет 0.4650. Полный байесовский вывод даёт 0.4096 - выигрыш порядка -0.055 в NLL. Это и есть основное улучшение на пути к опорному бейзлайну.

Анализ выигрыша на уровне отдельных пользователей через **per-user delta-LL** даёт следующую картину (рис. 6):




Figure 6: Per-user delta-LL: Rolling Seasonal $\rightarrow$ Personalized

Распределение $\Delta\text{LL} = \text{LL}_{\{\text{PersGP}\}} - \text{LL}_{\{\text{RS}\}}$ по пользователям сильно неоднородно:

- `share(personalized > rolling seasonal) = 66%` - две трети пользователей выигрывают от персонализации.
- Юзеры с 0..2 покупками выигрывают почти всегда (87..94%) - для них Personalized GP правильно сдвигает прогноз вниз от среднего по когорте.
- Бакет 6..10 покупок - наоборот, проигрывает (18%): на этих пользователях регуляризация ещё ощутимо тянет к когортному среднему, и чистая MLE сработала бы лучше.
- Активные с 11+ снова выигрывают, потому что $\hat{\mu}_u^{\text{EB}}$ на них почти не отличается от MLE.

4.3 Scaled-baseline Hawkes на персонализированной базе

Над Personalized Gamma-Poisson бейзлайном мы строим Scaled-baseline Hawkes - модель с фиксированной персонализированной базой и pooled Хоукс-надстройкой:

$$\lambda_{u,t} = c \cdot \mu_u^{EB} \cdot b_t + \sum_{j,m} \alpha_{j,m} \cdot z_{u,j,m,t},$$

где c - глобальный масштаб базы (один скаляр на всю когорту), а $z_{u,j,m,t}$ - Hawkes-state с полураспадом m для фичи j . В основной реализации мы используем 5 фичей $\times$ 2 полураспада (1, 3) дня, что даёт 10 параметров α и один скаляр c - итого 11 обучаемых параметров.

Обучение двухступенчатое (staged):

1. **ЕВ-шаг** (наследуется из бейзлайна): из Personalized GP получены μ_u^{EB} , (α, β) и b_t . На этом шаге per-user multiplier'ы зафиксированы.
2. **Хоукс-шаг**: численная оптимизация (c, α) методом L-BFGS-B с ограничением $\alpha \geq 0$. Loss - Пуассоновский негативный log-likelihood с мягкой L2-регуляризацией:

$$\mathcal{L}(c, \alpha) = -\log p(y \mid c\lambda_{\text{base}} + X\alpha) + \lambda_\alpha \|\alpha\|_2^2 + \lambda_c (c - 1)^2.$$

На главном 207d-train Scaled Hawkes даёт test NLL 0.3958 против 0.4096 у Pers GP - улучшение -0.014 в NLL. Обученные параметры: $\hat{c} \approx 0.83$, $\|\alpha\|_2 \approx 0.016$. Тот факт, что $c < 1$, говорит о том, что оптимизатор слегка уменьшает фоновую часть, компенсируя её Хоукс-надстройкой. Это первый намёк на то, что между $c \cdot \mu_u$ и Hawkes-states существует trade-off, к которому мы вернёмся в части III.

Обученная матрица α [feature $\times$ half-life] визуализируется на рис. 7. Наибольшее значение по абсолютной величине получает коэффициент при self-history `to_ord` (`hl=3`); однако сам канал `to_ord` крайне разреженный, и даже при таком весе вклад этого ядра в общую интенсивность остаётся небольшим. Положительные α для `searches` и `to_cart` на масштабе 1 день соответствуют короткой воронке `search` $\rightarrow$ `cart` $\rightarrow$ `order` в пределах одной-двух сессий пользователя. Устойчивость коэффициентов мы отдельно исследуем в Части III.

Анализ per-user delta-LL (рис. 8) показывает, что Хоукс-надстройка даёт выигрыш у 63.4% пользователей. В отличие от перехода к персонализации, выигрыш распределён более равномерно по всем бакетам активности (54..80% пользователей выигрывают в каждом бакете).

Mean / median delta-LL: $+0.71$ / $+0.16$ на пользователя. Это значит, что среднее улучшение скромное, но устойчивое - нет хвоста пользователей, на которых Hawkes резко проигрывает бейзлайну. Это критичное практическое свойство: модель надёжна на всей когорте.




Figure 7: Тепловая карта Хоукс-коэффициентов: feature $\times$ half-life (Scaled Hawkes)




Figure 8: Per-user delta-LL: Personalized $\rightarrow$ Scaled Hawkes

Регуляризация и выбор полураспадов. Для модели на 11 параметрах с $\sim 2\text{М}$ строк train regularization-сетка $(\lambda_\alpha, \lambda_c) \in \{0, 0.01, 0.1, 1, 10, 100\}^2$ показывает, что результат не зависит от регуляризации в широком диапазоне: размах test NLL по всей сетке составляет менее 0.0005. В целом это согласуется с ожиданиями: у нас много данных, и всего 11 параметров.

Выбор полураспадов - отдельный методический вопрос. Мы тестировали значения $\tau \in \{0.5, 1, 2, 3, 5, 7\}$ дня в комбинации с разным числом параллельных ядер. Главные наблюдения:

- Один полураспад $\tau = 1$ день даёт самый простой и быстрый фит, однако проигрывает набору полураспадов (1, 3) примерно 700 LL на тестовой выборке.
- Комбинация (1, 3) дня даёт оптимум по test NLL и сохраняет интерпретируемость двух разделённых масштабов памяти: «немедленный» (сегодня $\rightarrow$ завтра) и «среднесрочный» (3-дневная сессия).
- Добавление дополнительных полураспадов почти не увеличивает скор на тесте. При этом веса ядер становятся менее стабильными: два длинных полураспада сильно скоррелированы, и линейная модель распределяет веса между ними фактически случайно.

В дальнейшем в работе используется конфигурация (1, 3) дня для всех Хоукс-моделей в частях 1, 2.

4.4 Joint Hawkes как альтернативная параметризация

Рядом со Scaled-baseline Hawkes мы вводим вторую Хоукс-параметризацию - Joint Hawkes, где per-user множители λ_u и коэффициенты α обучаются совместно напрямую через MLE с явной L2-регуляризацией:

$$\lambda_{u,t} = \lambda_u \cdot b_t + \alpha^\top z_{u,t}, \quad \mathcal{L} = \text{NLL}(y, \lambda) + \lambda_{\ell_2} \sum_u (\lambda_u - 1)^2 + \lambda_\alpha \|\alpha\|_2^2.$$

Главные отличия от Scaled-baseline:

- Одностадийное обучение - без отдельного EB-шага. Empirical-Bayes prior на μ_u заменён явным L2-prior'ом $(\lambda_u - 1)^2$, и оптимизатор учитывает его одновременно с Хоукс-частью.
- λ_u обучается напрямую, а не наследуется зафиксированным из бейзлайна. Это даёт оптимизатору свободу «перекинуть» массу интенсивности между λ_u и Хоукс-вкладом - Scaled-baseline такой возможности не имеет, потому что μ_u^{EB} зафиксирован.

Обучаем всё так же, численно с помощью L-BFGS-B. Сходимость получается довольно быстрой.

На главном 207d-train Joint Hawkes даёт почти то же качество, что и Scaled-baseline (test NLL 0.3951 vs 0.3958) - по NLL модели на полном объёме данных практически неотличимы. Но отмечу, что структура регуляризации у них принципиально разная. Одинаковый скор не означает автоматически, что мы сошлись в одинаковые оптимумы. В дальнейшем будем исследовать этот момент подробнее.

4.5 Бустинг и feature engineering

Чтобы сравнение Хоукс-моделей с бустингом было объективным, бустинг мы тоже старались максимально вытянуть. Основной рычаг улучшения оказался со стороны **feature engineering**: из 5 исходных поведенческих счётчиков (`searches`, `cat_to_cart`, `cat_to_ord`, `to_cart`, `to_ord`) и нескольких производных каналов мы построили **141 фичу**, покрывающую историю, тренды, ЕМА, recency и funnel-ratio. Конкретный набор признаков можно сгруппировать:

- **Календарные (3)**: `dow`, `days_seen`, `week_idx`.
- **History по каждому source-каналу** ($14 \times 8 = 112$): `*_yesterday`, `*_sum3`, `*_sum7`, `*_mean7`, `*_active_days7`, `*_exp3`, `*_last_active`, `*_days_since_last_active`.
- **Агрегаты по заказам и активности**: `orders_hist_mean`, `carts_hist_mean`, `any_activity_sum7`, `any_activity_mean7` и т.п.
- **ЕМА**: `to_ord_ewm7`, `to_ord_ewm28`, `to_ord_ewm_gap_7_28`, `to_cart_ewm7`, `to_cart_ewm28`, `any_activity_ewm7`, `any_activity_ewm28`.
- **Recency и funnel-ratio**: `days_since_last_*`, `ord_per_cart_7`, `search_to_cart_rate_7`, `search_to_ord_rate_7`, `cat_to_cart_rate_7`, `cat_to_ord_rate_7`.

В качестве модели используем `HistGradientBoostingRegressor` с `Poisson loss`. Финальные гиперпараметры: `max_iter=200`, `max_depth=5`, `learning_rate=0.05`, `min_samples_leaf=40`, early stopping по held-out fraction. Со стороны гиперпараметров мы провели несколько точечных экспериментов (вариации глубины, learning rate, числа итераций), но заметного отклика по NLL они не дали - в итоге зафиксировали усреднённо-разумную конфигурацию без агрессивного тюнинга.

Test NLL бустинга - 0.3881, что лучше Scaled-baseline Hawkes (0.3958). Выигрыш составляет $-0.007.. - 0.008$ в NLL. Это означает две вещи. Во-первых, GBDT действительно ловит дополнительный сигнал, которого нет в Hawkes - вероятно, нелинейные взаимодействия между фичами. Во-вторых, его абсолютное улучшение относительно Hawkes мало по сравнению с разрывом между Hawkes и теоретическим saturated floor (0.0862): даже сильная бустинг-модель с 141 фичей закрывает лишь небольшую долю этого разрыва. Мы интерпретируем это как косвенный признак того, что большую часть оставшегося разрыва составляет шум в данных - сигнал, который не извлекается ни линейной additive формой Hawkes, ни нелинейной формой GBDT на имеющихся признаках.

В работе GBDT отмечается отдельным цветом - как reference point, дающий верхнюю планку качества. Цель - оценить, на каком расстоянии от этой планки находятся интерпретируемые Хоукс-модели.

4.6 Итоговая лестница моделей

Соберём все рассмотренные модели в единую сводную картину. Получается лестница из шести вероятностных моделей плюс GBDT и теоретический saturated floor:

1. Global Poisson - единая константа $\bar{\lambda}$ на весь датасет.

2. Rolling Poisson - скользящее среднее дневного уровня, без персонализации.
3. Rolling Seasonal Poisson - с поправкой на день недели.
4. Personalized Gamma-Poisson - персонализация множителем μ_u на предыдущую модель через Байесовский вывод.
5. Scaled-baseline Hawkes - Personalized GP с Хоукс-надстройкой.
6. Joint Hawkes - совместная оптимизация λ_u и α напрямую через MLE с L2-prior'ом (см. подсекцию выше).
7. GBDT - control-модель на расширенном feature-engineering'e (см. предыдущую подсекцию).

Каждый следующий уровень включает в себя структуру предыдущего и добавляет один концептуальный шаг.

Самый крупный единичный шаг ожидаемо приходится на персонализацию (Gamma-Poisson, -0.0480 в NLL): без неё модель неизбежно усредняет активных и неактивных пользователей. Все четыре «не персонализированных» бейзлайна почти не отличаются друг от друга - разброс между пользователями кратно превышает изменчивость во времени.

Содержательно более интересен следующий шаг: Хоукс-надстройка даёт значимый прирост поверх и без того сильного персонализированного бейзлайна (-0.0138 в NLL). Joint Hawkes отличается от Scaled-baseline всего на -0.0007 - на уровне численного шума, поэтому говорить о выигрыше одной параметризации над другой на полном train не приходится.

GBDT, как и положено сильной табличной модели на 141 фиче, занимает верхнюю планку (-0.0070 в NLL поверх Joint Hawkes), но отрыв от Хоукс-моделей минимален. Если посчитать, какую долю зазора между Personalized GP и GBDT закрывают Хоукс-модели, получится $\sim 64\%$ для Scaled-baseline и $\sim 67\%$ для Joint Hawkes - то есть Хоукс-надстройка одна снимает около двух третей всего «выжимаемого» бустингом сигнала, при существенно более простой и интерпретируемой структуре.

Наглядно лестница по per-observation NLL представлена на рис. 9.

Кратко главные наблюдения:

- Крупный шаг по NLL даёт переход к персонализации.
- Хоукс-надстройка добавляет ещё стабильный шаг порядка 0.014 в NLL.
- Между Scaled-baseline и Joint Hawkes разница ничтожна (0.0007 в NLL).
- GBDT обходит все вероятностные модели, но без интерпретируемой структуры и с очень небольшим отрывом.

Доля закрытого зазора между Global Poisson и saturated floor'ом, накопленная к Joint Hawkes, составляет $\sim 18\%$; до GBDT - $\sim 19\%$. Тот факт, что даже сильная бустинг-модель закрывает лишь немногим больше Joint Hawkes, мы интерпретируем как косвенное указание на то, что значительную часть оставшихся $\sim 80\%$ составляет шум в данных - сигнал, не извлекаемый ни линейной additive формой Hawkes, ни нелинейной формой GBDT на текущих признаках.




Figure 9: Per-observation NLL: лестница моделей

Ступень	Модель	Test LL	NLL/n	Δ vs предыдущая (NLL)
1	Global Poisson	-236458	0.4608	-
2	Rolling Poisson	-234805	0.4576	-0.0032
3	Rolling Seasonal	-234782	0.4576	-0.0000
4	Personalized Gamma-Poisson	-210167	0.4096	-0.0480
5	Scaled-baseline Hawkes	-203093	0.3958	-0.0138
6	Joint Hawkes ($\lambda_u + \alpha$)	-202721	0.3951	-0.0007
7	GBDT (experimental)	-199154	0.3881	-0.0070
-	Saturated Poisson floor	-44216	0.0862	-

Численная сводка по всем ступеням:

Вторичные метрики (абсолютный LL и RMSE) повторяют ту же лестницу. В LL: переход к персонализации даёт скачок порядка +24К, Хоукс-надстройка - ещё +7К, GBDT улучшает Joint Hawkes ещё на +3.6К. RMSE монотонно убывает от бейзлайна к Hawkes (0.655 $\rightarrow$ 0.627); GBDT практически совпадает с Joint Hawkes по RMSE (0.6297 vs 0.6291). Сводный график - рис. 10.




Figure 10: Test LL и RMSE по моделям

4.7 Декомпозиция интенсивности: Scaled-baseline vs Joint Hawkes

Главный test NLL у Scaled-baseline Hawkes и Joint Hawkes практически совпадает. Это естественно поднимает вопрос: учат ли эти модели одно и то же разложение интенсивности на бейзлайн-часть и Хоукс-надстройку, или приходят к разным внутренним структурам, лишь случайно дающим одинаковый общий скор?

Чтобы это проверить, строим scatter обученных per-user multiplier'ов: m_u из Scaled-baseline Hawkes (где $m_u = c \cdot \mu_u^{EB}$) против m_u из Joint Hawkes (где $m_u = \lambda_u$ напрямую).




Figure 11: Per-user m_u : Scaled-baseline vs Joint Hawkes

Структурные эффекты:

- **Средние значения** (красный крест): $m_{staged} \approx 0.823$, $m_{joint} \approx 0.649$. Joint в среднем занижает множитель сильнее, компенсируя это примерно в 2 раза большим $\|\alpha\|_2$ (0.0324 vs 0.0161).
- **Корреляция** $\text{corr}(m_{staged}, m_{joint}) = 0.85$ - высокая, но не единица: модели договариваются о том, кто более активный, но конкретные значения отличаются.
- **Активные пользователи** (правый хвост) тоже зачастую ниже диагонали: joint-фит снижает per-user multiplier, оставляя место большой Хоукс-надстройке.

Несмотря на эти разные декомпозиции, итоговый test NLL обеих моделей практически совпадает. Это и есть тот самый $c - \alpha$ trade-off: разные оценки (m_u, α) дают почти одинаковую общую интенсивность. На уровне population-NLL модели неотличимы; на уровне внутренних параметров - существенно разные. Это наблюдение играет центральную роль в части III, где мы разворачиваем его в полноценный анализ identifiability через profile likelihood.

5 Часть II. Поведение моделей на коротких train-окнах

Все результаты Части I получены на 207-дневном train. Возникает естественный вопрос: насколько эти выводы устойчивы к выбору train-окна? В промышленных задачах часто доступны только короткие истории (14..30 дней - например, в задачах быстрого онбординга новых сегментов или анализа А/В-эксперимента), и важно понять, какая параметризация Hawkes выживает на таких окнах.

5.1 Blockwise CV: 21-дневные блоки

Первый эксперимент - blockwise cross-validation с непересекающимися 21-дневными блоками. Анализируемый период 2025-01-15..2025-09-30 бьётся на 13 блоков. В каждом блоке первые 14 дней используются как train, последние 7 - как test. На каждом блоке независимо обучаются все шесть моделей лестницы плюс GBDT.




Figure 12: Blockwise CV: per-block NLL

На коротких train (14d) картина меняется по сравнению с главным окном. Несколько ключевых наблюдений:

- **Все «не персонализированные» бейзлайны** (Global, Rolling, Rolling Seasonal) дают практически одинаковый mean NLL ~ 0.404 . Это и ожидаемо: rolling-mean на 14 днях не сильно отличается от глобального среднего, а недельная сезонность на 14 днях оценивается шумно.
- **Personalized Gamma-Poisson** даёт mean NLL ~ 0.372 - персонализация через Empirical Bayes остаётся устойчивым шагом и здесь. Абсолютные значения у всех моделей ниже, чем на главном train (там Pers GP давал ~ 0.41), - это связано в первую очередь с тем, что test-окно тут всего 7 дней, а на главном протоколе - 52, поэтому среднее по более короткому test шумнее и в среднем ниже.
- **Scaled-baseline Hawkes вырождается** на этих окнах: Хоукс-веса прижимаются к нулю, и модель фактически становится копией Personalized GP - отсюда и совпадение mean NLL (~ 0.372). Подробно разбираем причину в следующей подсекции.

- **Joint Hawkes** даёт mean NLL ~ 0.363 - лучший среди вероятностных моделей, и заметно лучше Pers GP. Хоукс-надстройка здесь не вырождается. Тезис о том, что регуляризация (в том числе структурная) Хоукс-ядер влияет на итоговые веса, подтверждается.
- **GBDT** остаётся лидером по абсолюту с mean NLL ~ 0.345 .

Дисперсия результатов по блокам велика у всех моделей - это нормально для шумной разреженной задачи на коротких окнах: разные блоки попадают на разные участки активности когорты, и точечное значение NLL ощутимо плавают даже у одной и той же модели.

5.2 Вырождение Scaled-baseline Hawkes

Эффект вырождения Scaled-baseline Hawkes на 14d train особенно поучителен. Если посмотреть на обученные параметры на каждом блоке, видна следующая картина:

- $\hat{c} \approx 1.00$ (зажат к prior'у $c = 1$);
- $\|\alpha\|_2 \approx 0$ (все Хоукс-веса прижаты к нулю).

То есть модель полностью теряет Хоукс-надстройку и фактически сводится к Personalized GP. На уровне предсказательного качества это и подтверждается: их test NLL практически совпадают.

Почему так получается. На 14 днях у большинства пользователей всего 0-2 события целевого канала, и EB-prior тянет μ_u^{EB} к среднему по когорте. С одной стороны, Personalized GP уже неплохо подгоняет такие редкие события одним per-user уровнем - оптимизатору почти нечего «доулучшать» Хоукс-надстройкой. С другой стороны, событий, на которых Хоукс-ядро вообще могло бы себя показать, тоже мало: $z_{u,j,t}$ редко отличается от нуля, и его в среднем не отличить от собственно бейзлайна. В итоге оптимизатор предпочитает оставить ровно одну компоненту - бейзлайн, тем более что его prior подталкивает $c \rightarrow 1$.

Вырождение мотивирует переход к другой форме обучения, которая бы не позволяла Хоукс-надстройке схлопнуться к нулю.

5.3 Joint Hawkes на коротких окнах

Joint Hawkes (определение и обучение разобраны в Части I) построен так, что вместо двухступенчатого EB-prior'a на μ_u использует явную L2-регуляризацию per-user множителей $(\lambda_u - 1)^2$ напрямую при совместной оптимизации с α . Это отличие, малозаметное на полном train (test NLL практически одинаковый со Scaled-baseline), оказывается решающим на коротких окнах.

Активный L2-prior удерживает λ_u в окрестности единицы: оптимизатор не может «зажать» все λ_u в ноль и переложить весь сигнал на Хоукс-часть (или наоборот). На 14d-train Joint Hawkes **не вырождается**: $\|\alpha\|_2 \approx 0.04..0.05$ на всех n от 15 до 200 дней. То есть Хоукс-надстройка остаётся ненулевой и информативной даже там, где у Scaled-baseline она схлопывается до нуля.

По умолчанию используем $\lambda_{\ell_2} = 1$ как «активный prior». Чувствительность результата к этой константе подробно разбираем в Части III; здесь она фиксирована.

5.4 Train-length scan и crossover’ы

Систематический анализ - sweep по длине train-окна $n \in \{15, 21, 27, 36, 48, 63, 84, 114, 153, 198\}$ дней. На каждом значении n берётся m случайных интервалов из анализируемого периода (с фиксированным seed), и для каждого интервала строится разбиение $2n/3$ train + $n/3$ test. На каждом запуске обучаются все семь моделей. Это позволяет получить distribution test NLL для каждой пары (модель, n) и оценить как mean, так и дисперсию.

Сводный график mean test NLL по моделям от n - рис. 13.




Figure 13: Mean NLL по моделям от длины окна

Видно чёткое разделение по зонам n :

- На $n \leq 21$ Joint Hawkes лидирует с заметным отрывом ($\sim 0.02..0.05$ в NLL): Scaled-baseline в этой зоне вырождается, а Joint с активной L2-регуляризацией удерживает Хоукс-сигнал.
- На $n \in [27, 60]$ ситуация переворачивается: Joint Hawkes становится хуже Scaled-baseline и Personalized GP. Похоже, что выставленная по умолчанию сила L2-регуляризации ($\lambda_{\ell_2} = 1$), удерживающая модель от вырождения на самых коротких окнах, на этих промежуточных длинах уже излишне ограничивает λ_u и Хоукс-веса.
- На $n \geq 100$ Scaled-baseline и Joint Hawkes по test NLL сравниваются и оба обходят Personalized GP примерно на ~ 0.02 в NLL. Важно подчеркнуть: совпадение здесь только по *итоговому* NLL - сами оптимумы (λ_u, α) у двух моделей различны (см. подсецию 4.7 про декомпозицию интенсивности).

GBDT остаётся лучшим в абсолютe на всех n , но разрыв уменьшается с ростом n - на длинных train probabilistic-модели догоняют бустинг. На $n = 198$ день разрыв Joint Hawkes vs GBDT составляет ~ 0.009 в NLL против ~ 0.014 на $n = 15$.

Поведение нормы Хоукс-коэффициентов и среднего per-user multiplier’а от n - рис. 14 и 15.




Figure 14: Норма $\|\alpha\|_2$ по моделям от длины окна




Figure 15: Средний per-user multiplier от длины окна

Здесь хорошо видно вырождение: для Scaled-baseline $\|\alpha\| = 0$ на всех $n \leq 50$ (плоское ноль), и только с $n \approx 80$ норма начинает расти. На $n = 198$ норма достигает ~ 0.012 , что близко к значению ~ 0.016 , полученному на полном 207d-train. У Joint Hawkes $\|\alpha\|$ стабилен ($\sim 0.04..0.05$) с самого $n = 15$, медленно убывая к ~ 0.037 на больших n . Mean per-user multiplier λ_u у Joint Hawkes держится $\sim 0.65..0.75$ независимо от n , что согласуется с активной L2-регуляризацией к единице.

Кроме того видно, что у Scaled-baseline норма $\|\alpha\|$ стабильно растёт с увеличением числа дней обучения. Логично предположить, что это происходит потому, что на больших выборках слабый Хоукс-сигнал получается лучше различать в шумных данных. Вполне вероятно, что на ещё более длинных данных Хоукс-веса двух параметризаций сошлись бы к одному значению. Но на нашем диапазоне n даже на 200 днях разница между ними остаётся значительной.

Главный вывод этой части: Хоукс-сигнал в данных действительно присутствует, но он слабый, и форма регуляризации существенно меняет картину. При структурной регуляризации через двухступенчатый EB-fit (Scaled-baseline) на коротких train Хоукс-сигнал не отделяется от бейзлайна и поглощается переобученным per-user множителем - модель вырождается фактически до Personalized GP. Scaled-baseline за счёт этого нигде заметно не проигрывает Pers GP - в зоне вырождения он просто совпадает с ним. При явной L2-регуляризации (Joint Hawkes) Хоукс-надстройка сохраняется на всём диапазоне n , но это не «бесплатно»: на самых коротких окнах ($n \leq 21$) Joint Hawkes выигрывает, тогда как на промежуточных ($n \in [27, 60]$) тот же активный L2-prior уже излишне ограничивает модель, и Joint Hawkes на этих длинах оказывается даже хуже Pers GP. Устойчивое преимущество Хоукс-надстройки над Personalized GP начинается с $n \approx 80$ дней и дальше только накапливается. Таким образом, длина train-окна имеет принципиальное значение: на коротких окнах значимого выигрыша от Хоукс-надстройки ждать не стоит, а начиная с ~ 80 дней он становится стабильным.

6 Часть III. Структура cross-channel Хоукс-матрицы

В первой части мы рассматривали один target - `to_ord` - и вектор α по нескольким source-каналам. В этой части переходим к cross-channel постановке: на каждый из трёх каналов воронки (`searches`, `to_cart`, `to_ord`) подгоняется собственная Хоукс-модель, у которой источниками возбуждения служат все три канала (включая сам себя). Получается интерпретируемая матрица $\alpha \in \mathbb{R}^{3 \times 3}$ пар-канальных взаимодействий - диагональ описывает self-excitation каждого канала, off-diagonal - cross-channel влияние.

6.1 Cross-channel постановка и верификация

Бейзлайн для каждого из трёх каналов (`searches`, `to_cart`, `to_ord`) строится точно так же, как в Части I: Personalized Gamma-Poisson с собственным per-user множителем $\mu_u^{\text{EB},k}$ и собственным дневным профилем $b_t^{(k)}$ для каждого target-канала k . Поверх него натягивается Хоукс-надстройка, источниками возбуждения которой служат все три канала (включая сам себя):

$$\lambda_{u,t}^{(k)} = c_k \cdot \mu_u^{\text{EB},k} \cdot b_t^{(k)} + \sum_{j=1}^3 \alpha_{kj} \cdot z_{u,j,t}.$$

Hawkes-state $z_{u,j,t}$ строится с тем же полураспадом 1 день, оптимизация выполняется отдельно по каждому target'у. Главный α -объект исследования - матрица $\alpha \in \mathbb{R}^{3 \times 3}$ пар-канальных взаимодействий: диагональ описывает self-excitation каждого канала, off-diagonal - cross-channel влияние.

Верификация: даёт ли Хоукс-надстройка прирост на каждом канале? Прежде чем разбираться в структуре матрицы α , нужно убедиться, что Хоукс-надстройка вообще полезна для всех трёх каналов (для `to_ord` это уже показано в Части I, а `searches` и `to_cart` - новые target'ы). Сравнение per-channel test NLL у Pers GP, Scaled Hawkes и GBDT приведено на рис. 16.




Figure 16: Per-channel верификация: Pers GP vs Scaled Hawkes vs GBDT

Хоукс-надстройка улучшает Pers GP на всех трёх каналах; GBDT (141 фича на каждый канал) задаёт верхнюю планку. Интересная закономерность - чем плотнее канал, тем большую долю прироста бустинга поверх Pers GP объясняют сами Хоукс-ядра: на `searches` Hawkes закрывает $\sim 77\%$ gap'a от Pers GP до GBDT, на `to_cart` $\sim 67\%$, на разреженном `to_ord` - $\sim 54\%$. То есть на богатых каналах большая часть «выжимаемого» сигнала структурно описывается линейной additive Хоукс-формой, а нелинейные взаимодействия играют относительно меньшую роль.

Точечная оценка матрицы α на главном train. Восстановленная матрица для Scaled-baseline Hawkes на 207d-train приведена на рис. 17.




Figure 17: Cross-channel α -матрица на главном train (Scaled-baseline)

Численные значения:

target ↓ \ source →	searches	to_cart	to_ord
searches	0.1269	0.0240	0
to_cart	0.0103	0.0713	0
to_ord	0.0030	0.0046	0.0194

Визуально матрица показывает осмысленную структуру воронки:

- **Верхне-треугольная часть колонки to_ord идентично нулевая:** краткосрочных Хоукс-эффектов от to_ord на searches и to_cart мы не наблюдаем.
- **Off-diagonal funnel-связи searches → cart → order различимы и положительны:** $\alpha[to_cart \leftarrow searches] = 0.010$, $\alpha[to_ord \leftarrow to_cart] = 0.0046$. Это согласуется с физической воронкой: поиск повышает интенсивность добавления в корзину, корзина повышает интенсивность покупки.
- **Self- α** $\alpha[to_ord \leftarrow to_ord] = 0.019$ ненулевой, но небольшой - и, как мы увидим в следующих подсекциях, плохо идентифицируется на наших данных.

Здесь нужно сделать важную оговорку. В Части II мы уже несколько раз видели, что коэффициенты α Хоукс-ядер ощутимо зависят и от длины train-выборки, и от выбора регуляризации. Поэтому значения в таблице выше следует понимать как **точечную оценку на одном конкретном train при конкретном способе регуляризации** - часть из них меняется на десятки процентов при варьировании окна или λ_{ℓ_2} . Точная интерпретация каждого коэффициента, его чувствительность к регуляризации и доверительные интервалы разбираются в следующих подсекциях.

6.2 Стабильность коэффициентов: train-окно и регуляризация

Из мотивации прошлых глав следует, что стабильность кросс-Хоукс матрицы нужно исследовать по двум осям: длина train-окна и сила/форма регуляризации. В этой подсекции мы сначала смотрим на коэффициенты Scaled-baseline на bootstrap'e и при изменении длины окна, потом сравниваем с Joint Hawkes при разных λ_{ℓ_2} , и сопоставляем обе картины.

Bootstrap Scaled-baseline по 10 случайным 100d-окнам показывает заметную нестабильность точечной оценки. Mean $\pm$ std по окнам:

ячейка	mean α	std	CV
searches $\leftarrow$ searches	0.0798	0.0058	7.2%
searches $\leftarrow$ to_cart	0.0168	0.0026	15.5%
to_cart $\leftarrow$ searches	0.0060	0.0009	15.6%
to_cart $\leftarrow$ to_cart	0.0347	0.0034	9.7%
to_ord $\leftarrow$ searches	0.0011	0.0005	47.4%
to_ord $\leftarrow$ to_cart	0.0025	0.0009	36.2%
to_ord $\leftarrow$ to_ord	0.0016	0.0024	148.3%

Даже при фиксированной длине окна оценка ощутимо плавает: для редких пар CV доходит до 36..47%, а $\alpha[to_ord \leftarrow to_ord]$ фактически коллапсирует. Если сравнить эти значения с точечной оценкой на главном 207d-train, видно, что все коэффициенты на коротком окне систематически ниже - Scaled-baseline на 100d недообучает всю матрицу, а не только диагональ; диагональные коэффициенты при этом страдают сильнее off-diagonal.

Joint Hawkes на том же 100d-bootstrap'e ведёт себя качественно иначе. С активной регуляризацией ($\lambda_{\ell_2} = 1$) он удерживает $\alpha[to_ord \leftarrow to_ord] = 0.038$ при CV 14.7%; без регуляризации ($\lambda_{\ell_2} = 0$) - снова коллапсирует. Сравнение трёх режимов - рис. 18.




Figure 18: Сравнение трёх режимов: Scaled vs Joint($\lambda_{\ell_2} = 1$) vs Joint($\lambda_{\ell_2} = 0$)

Из рис. 18 видны две вещи. Во-первых, у Joint Hawkes на λ_{ℓ_2} сильнее всего реагируют именно диагональные элементы, а off-diagonal остаются относительно стабильными. Во-вторых, off-diagonal элементы Joint Hawkes на 100d-bootstrap'e по величине близки к off-diagonal Scaled-baseline на длинном 207d-train - тогда как сам Scaled-baseline на тех же 100d-окнах даёт заметно меньшие off-diagonal.

Связующий вывод. Scaled-baseline на небольших train-выборках систематически недообучает всю матрицу, в том числе off-diagonal; длинный train выводит off-diagonal на устойчивый уровень. Joint Hawkes с активной L2-регуляризацией добивается похожего

уровня off-diagonal уже на коротких окнах - за счёт явного prior'a. Диагональные коэффициенты ни в одном из режимов стабильно не восстанавливаются: их точечное значение существенно зависит и от длины окна, и от λ_{ℓ_2} . Этот факт мы формализуем дальше через profile likelihood. Регуляризация может быть либо структурной (EB-fit у Scaled-baseline), либо численной (λ_{ℓ_2} у Joint Hawkes); оба варианта меняют точечные оценки α в одну сторону - перераспределяют массу между бейзлайн-частью и Хоукс-надстройкой.

6.3 Зависимость Хоукс-матрицы Joint Hawkes от коэффициента регуляризации

Чтобы понять, как именно регуляризация перераспределяет внутреннюю структуру модели, проведён sweep по $\lambda_{\ell_2} \in \{0, 0.01, 0.05, 0.1, 0.3, 0.5, 1, 2, 5\}$ на главном 207d-train для каждого из 3 target'ов. Разложение интенсивности на бейзлайн-часть $\lambda_u \cdot b_t$ и Хоукс-часть $\alpha^\top z$ показано на рис. 19.




Figure 19: Trade-off: масса baseline vs Hawkes от λ_{ℓ_2}

С ростом λ_{ℓ_2} оптимизатор зажимает λ_u к 1, и масса перетекает из бейзлайн-части в Хоукс-надстройку - на всех 3 каналах, сильнее всего на разреженном to_ord. То есть α выступает компенсаторной переменной по отношению к λ_u . При этом test NLL почти не меняется на всей сетке (рис. 20): размах ≤ 0.01 на всех каналах. Разные λ_{ℓ_2} дают разные внутренние разложения (λ_u, α) , но почти одинаковое predicted intensity на test - модель сверх-параметризована на уровне параметров, но предсказательно устойчива.




Figure 20: Test NLL от λ_{ℓ_2}

Разрешение α по λ_{ℓ_2} - рис. 21. Off-diagonal funnel-связи устойчивы ($\pm 2..10\%$), $\alpha[\text{searches} \leftarrow \text{searches}]$ почти не реагирует ($\pm 4\%$): канал богат событиями, self-сигнал отделяется от бейзлайна устойчиво. $\alpha[\text{to_cart} \leftarrow \text{to_cart}]$ меняется умеренно ($\pm 13\%$), а $\alpha[\text{to_ord} \leftarrow \text{to_ord}]$ - сильно ($+82\%$, $0.030 \rightarrow 0.055$). Чем разреженнее target, тем сильнее зависимость диагонального коэффициента от регуляризации; этот вывод формализуем дальше через profile likelihood.




Figure 21: Зависимость α от λ_{ℓ_2} - 3×3 сетка

6.4 Profile likelihood и асимметрия диагонали/внедиагональных

Мы хотим внимательнее рассмотреть, как устроен ландшафт лосса вокруг обученной модели. Для этого попробуем по очереди фиксировать каждый Хоукс-коэффициент на разных значениях, переобучать все остальные параметры модели и смотреть, какого NLL удаётся при этом добиться. Если профиль NLL получается узкий и с выраженным минимумом - значит, данные действительно «выбирают» одно значение коэффициента; если плоский - значит, целая полоса значений почти одинаково хороша, и точечная оценка несёт мало информации. Из таких профилей естественно строить границы, в которых Хоукс-коэффициенты можно варьировать без заметной просадки по NLL - это и есть метод profile likelihood.

Сам эксперимент устроен так. Для каждой пары канал-источник (k, j) :

1. Обучаем Joint Hawkes без каких-либо фиксаций - это даёт опорную точку $(\hat{\lambda}_u, \hat{\alpha})$.
2. Строим сетку из 11 значений для α_{kj} - от 0 до $\max(0.10, 2 \cdot \hat{\alpha}_{kj})$, чтобы покрыть и небольшие, и удвоенные относительно опорной точки значения.

3. На каждом значении сетки фиксируем α_{kj} и переобучаем оставшиеся параметры модели для этого канала-target'a: per-user множители λ_u и два других коэффициента строки $\alpha_{k,\cdot}$.
4. Считаем для каждой из 11 точек train NLL и test NLL - так получается profile-кривая для одной ячейки матрицы.

Чтобы оптимизатор не зависал в локальных минимумах при фиксации, идём по сетке последовательно от точки, ближайшей к опорной, и каждый следующий fit стартует с параметров предыдущего. Затем делаем два дополнительных прохода по уже найденным точкам с обновлённой опорной точкой. Это убирает дискретные скачки в profile NLL из-за неудачной инициализации.

Полная 3×3 картина для train NLL приведена на рис. 22, для test NLL - на рис. 23.




Figure 22: Train NLL profile по 9 коэффициентам

Топология profile'ей характеризуется тремя группами:

- Жёсткие коэффициенты ($rangeNLL \geq 0.03$): $to_ord \leftarrow searches$ (range test NLL 0.103), $searches \leftarrow searches$ (0.096), $to_cart \leftarrow searches$ (0.031). Здесь данные реально различают значения коэффициента - profile NLL имеет ярко выраженный минимум.
- Плоские коэффициенты ($rangeNLL \leq 0.005$): вся колонка $\alpha[* \leftarrow to_ord]$ плюс $\alpha[searches \leftarrow to_cart]$ и $\alpha[to_ord \leftarrow to_ord]$ (range 0.002). Данные на эти значения практически не реагируют - profile NLL почти константа.
- Промежуточные: $to_ord \leftarrow to_cart$ (0.018), $to_cart \leftarrow to_cart$ (0.015).




Figure 23: Test NLL profile по 9 коэффициентам

Топология не зависит от prior'a: control-эксперимент без регуляризации ($\lambda_{\ell_2} = 0$, $\lambda_{\alpha} = 0$) даёт практически те же range'и (с расхождением во втором-третьем знаке). То есть профили - это свойство геометрии данных, а не выбор регуляризации.

Особенно интересно, что диагональный $\alpha[\text{to_ord} \leftarrow \text{to_ord}]$ оказался плоским, несмотря на то, что в линейном фите получает ненулевое значение ~ 0.03 . Причина простая: собственная история диагонального канала $z_{u,t}^{(k)}$ в среднем пропорциональна $\lambda_u^{(k)} \cdot b_t$ - то есть тому же сигналу, что и бейзлайн-часть $\lambda_u \cdot b_t$. Два почти коллинеарных регрессора сложно разделить: оптимизатор может объяснить интенсивность как за счёт большого λ_u и маленького α_{kk} , так и наоборот - и обе комбинации дадут практически одинаковую $\hat{\lambda}$. Для внедиагональных коэффициентов история относится к другому каналу, не коллинеарному бейзлайну, поэтому такой проблемы нет, и значение восстанавливается устойчиво. То, что неидентифицируемость возникает именно на диагонали разреженного канала, - известный теоретический результат [4, 5].

В литературе эта же проблема обсуждается в двух подходах:

- Bacry, Bompair, Gaïffas, Muzy [4] предлагают separate regularization для диагональных (ℓ_1 -штраф) и внедиагональных (trace norm) элементов, именно потому, что диагональ absorbs baseline mass.
- Achab, Bacry, Gaïffas, Mastromatteo, Muzy [5] отказываются от MLE в пользу integrated cumulants, чтобы обойти diagonal/baseline non-identifiability на коротких выборках.

В нашей работе мы не используем эти методы напрямую - мы признаём диагональ слабо идентифицируемой и формализуем это через интервалы значений вместо точечной оценки (раздел 6.4).

Эмпирическая закономерность: качество идентификации диагонального коэффициента падает по мере разрежения соответствующего target-канала. На богатом событиями `searches` диагональ выделяется хорошо (range NLL 0.096), на промежуточном `to_cart` - умеренно (0.015), на разреженном `to_ord` - практически плоский профиль (0.002). Это согласуется с интуицией: чтобы оптимизатор смог разделить вклад собственного history-state и бейзлайна, нужно достаточное число событий target-канала.

Сравнение train и test profile'ей подтверждает ту же картину. Для off-diagonal коэффициентов и для self- α богатого канала `searches` train и test profiles совпадают по топологии и положению минимума - данных хватает, чтобы оценка не была артефактом обучения. У слабо идентифицируемых диагональных коэффициентов (в первую очередь у $\alpha[to_ord \leftarrow to_ord]$) train profile склонен показывать более узкий и глубокий минимум, чем test - то есть на разреженной диагонали модель легко переобучается под тренировочный сигнал, а её точечная оценка определяется в большей мере регуляризатором, чем данными.

6.5 Интервалы 10%-gain и финальная матрица

Из плоского profile NLL следует, что точечная оценка $\alpha[i, j]$ для плоских коэффициентов малоинформативна. Корректнее говорить интервалом: значение лежит где-то в широком диапазоне, и модель не различает точки внутри него.

Доверительный интервал для каждой ячейки α_{kj} мы строим через выигрыш Хоукс-модели над Personalized GP бейзлайном этого канала. Обозначим $gain = NLL_{PG} - NLL_{min}$, где NLL_{PG} - test NLL Personalized GP, а NLL_{min} - минимум test NLL Joint Hawkes по профилю для α_{kj} (без регуляризации, чтобы убрать эффект prior'a). Допустимыми считаем такие α_{kj} , при которых модель сохраняет хотя бы 90% этого выигрыша, и берём непрерывный диапазон вокруг минимума профиля, где это условие выполнено - его границы и есть α_{lo}, α_{hi} , представительная точка - середина α_{mid} . Чем шире интервал, тем менее информативна точечная оценка коэффициента.

Численные результаты:

target $\leftarrow$ source	α_{lo}	α_{hi}	α_{mid}	width, % от mid
<code>searches $\leftarrow$ searches</code>	0.115	0.261*	0.188	78%
<code>to_cart $\leftarrow$ searches</code>	0.002	0.048	0.025	181%
<code>to_cart $\leftarrow$ to_cart</code>	0.047	0.143*	0.095	101%
<code>to_ord $\leftarrow$ searches</code>	0.008	0.014	0.011	54%
<code>to_ord $\leftarrow$ to_cart</code>	0.000	0.028	0.014	200%
<code>to_ord $\leftarrow$ to_ord</code>	0.017	0.100*	0.059	141%

Важная оговорка: значения α_{hi} со звёздочкой (*) - это правые края сеточного grid'a, на которых profile NLL ещё не превысил 10%-threshold. То есть для этих трёх ячеек наши эксперименты до правой границы интервала не дошли, и фактический верхний предел допустимых значений выше указанного. По принципу построения сетки (см. 6.4) мы шли до $2 \cdot \alpha_{anchor}$, и этого диапазона на диагонали оказалось мало.

Три ячейки верхнего треугольника (`searches  $\leftarrow$  to_cart`, `searches  $\leftarrow$  to_ord`, `to_cart  $\leftarrow$  to_ord`) имеют плоские профили с $range \leq 0.003$ в NLL - данные на них не реагируют. По convention воронки эти три коэффициента полагаем структурно нулевыми: даже на длинном 207d-train соответствующие эффекты слишком

10%-gain intervals over Personalized GP baseline (threshold = $\min + 0.1 \cdot (\text{PG} - \min)$, unregularized fit, $\lambda_{t_2} = 0$)




Figure 24: Интервалы 10%-gain для 9 коэффициентов

слабые, чтобы их выделить из данных, и для последующего анализа мы считаем их отсутствующими.

Финальная матрица midpoint'ов (рис. 25):

target ↓ \ source →	searches	to_cart	to_ord
searches	0.188	0	0
to_cart	0.025	0.095	0
to_ord	0.011	0.014	0.059

Матрица нижнетреугольная (по convention воронки), поэтому её собственные числа совпадают с диагональю: $|\text{eigvals}| = [0.059, 0.095, 0.188]$ для midpoint'ов. Однако из всех предыдущих разделов мы уже знаем, что именно диагональные коэффициенты идентифицируются плохо, и для каждого из них 10%-интервал получается широким. Поэтому корректнее смотреть не точечную оценку спектрального радиуса, а его интервал, унаследованный из интервалов диагональных коэффициентов:

собственное число	α_{lo}	α_{hi}	α_{mid}
searches ← searches	0.115	0.261*	0.188
to_cart ← to_cart	0.047	0.143*	0.095
to_ord ← to_ord	0.017	0.100*	0.059

Спектральный радиус по midpoint'ам $\rho(M) \approx 0.19$ - формально это значение можно цитировать как точечную оценку, но содержательнее интервал: левая граница около 0.12, правая упёрлась в правый край сетки и фактически выше 0.26. Даже на этой




Figure 25: Финальная Хоукс-матрица midpoint'ов

нижней границе $\rho < 1$, и Хоукс-процесс остаётся стабильным во всём допустимом диапазоне.

Финальный результат cross-channel анализа: 6-параметрическая нижнетреугольная матрица, описывающая self-exciting структуру воронки $\text{searches} \rightarrow \text{to_cart} \rightarrow \text{to_ord}$ с явно нулевыми «обратными» рёбрами. Off-diagonal коэффициенты идентифицируются устойчиво, диагональные - только в широких интервалах, что и фиксирует основное ограничение интерпретируемости модели на наших данных.

6.6 Per-user визуализация работы моделей

Чтобы понять различия Personalized GP и Joint Hawkes на уровне отдельных пользователей, мы строим для четырёх типичных юзеров timeline предсказанной интенсивности с фактическими покупками. Выборка пользователей сделана так:

- **активный** (612605): $Y_{\text{train}} = 321$, $Y_{\text{test}} = 93$. Регулярная высокая активность.
- **малоактивный** (238812): $Y_{\text{train}} = 6$, $Y_{\text{test}} = 2$. Редкие изолированные покупки.
- **Joint Hawkes выигрывает** (676128): $Y_{\text{train}} = 7$, $Y_{\text{test}} = 97$, $\text{Delta-LL}(\text{JH} - \text{GP}) = +151.7$. Скачок активности к концу окна.
- **Joint Hawkes проигрывает** (47946): $Y_{\text{train}} = 899$, $Y_{\text{test}} = 359$, $\text{Delta-LL} = -134.8$. Сверхактивный пользователь с большой дневной дисперсией.

Траектории Personalized GP - рис. 26, Joint Hawkes - рис. 27.




Figure 26: Personalized GP: traces 4 пользователей

У Personalized GP интенсивность практически постоянна для каждого пользователя - модель оценивает один числовой уровень $\mu_u^{EB} \cdot b_t$ и его экстраполирует. Поправка от b_t мала ($\pm 5\%$ внутри недели через Rolling Seasonal). У Joint Hawkes интенсивность **динамическая**: после каждого события $\hat{\lambda}$ экспоненциально подсвечивается и спадает к baseline с полураспадом 1-3 дня. Высота всплесков зависит от обученных α -весов и непосредственно от текущего состояния $z_{u,t}$.

На этих 4 примерах хорошо видно, в каких сценариях работает каждая из моделей:

- На малоактивном пользователе обе модели дают практически одинаковый средний уровень (~ 0.04), и разница $\Delta LL \approx 0.05$ пренебрежимо мала.
- На активном пользователе обе модели близки по среднему ($\sim 1.5..2/\text{день}$), но Joint Hawkes пульсирует, иногда overshoots и теряет немного на test ($\Delta LL = -17.5$).
- На пользователе с резким переходом режима (676128, мало покупок на train, всплеск на test) Joint Hawkes значительно выигрывает, потому что подхватывает начало роста через Hawkes-states: интенсивность поднимается до 5..10 в дни streak'ов. Pers GP остаётся flat у ~ 0.1 и платит большой NLL за каждый ненулевой день. $\Delta LL = +151.7$.
- На сверхактивном пользователе с высокой дневной дисперсией (47946) Joint Hawkes overreacts на крупные одиночные дни (где $y = 30..45$), и его $\hat{\lambda}$ доходит до 20+, тогда как на следующий день у пользователя часто только 2..3 покупки.




Figure 27: Joint Hawkes: traces 4 пользователей

Pers GP с более консервативным средним уровнем (~ 4.5) лучше согласуется. $\Delta LL = -134.8$.

На уровне population-NLL разница между моделями скромная (0.3958 vs 0.3951), но per-user ΔLL распределена сильно неоднородно - ± 150 для отдельных пользователей при mean'e ≈ 0 . Это означает, что с точки зрения общего качества модели почти эквивалентны, но в индивидуальных предсказаниях они существенно различны. Для бизнес-применения (например, ранжирование пользователей по ожидаемой выручке) это может быть важно: одна и та же population-метрика может скрывать разные паттерны ошибок.

7 Заключение

В работе исследовано применение процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce-сервисе на датасете из $\sim 10K$ пользователей за ~ 290 дней. Основные результаты сгруппированы по трём ветвям исследования.

Бейзлайн и Хоукс-надстройка на полном train-test (часть I). Построена последовательность из шести вероятностных моделей с переходом от Global Poisson к Joint Hawkes. Самый крупный единичный шаг ожидаемо приходится на персонализацию (Gamma-Poisson через Empirical Bayes, -0.048 в NLL): без неё модель неизбежно усредняет активных и неактивных пользователей. Содержательно более интересен следующий шаг - Хоукс-надстройка устойчиво улучшает уже сильный персонализированный бейзлайн на -0.014 в NLL. Поскольку данные табличные и наблюдений много, верхнюю планку качества ожидаемо задаёт бустинг (141 фича), но его отрыв от Хоукс-моделей небольшой: Scaled-baseline и Joint Hawkes покрывают $\sim 64\%$ и $\sim 67\%$ всего «выжимаемого» бустингом сигнала над Pers GP при существенно более простой и интерпретируемой структуре. На уровне отдельных каналов воронки Хоукс-надстройка тем больше объясняет gap'a Pers GP $\rightarrow$ GBDT, чем плотнее канал (от $\sim 54\%$ на разреженном `to_ord` до $\sim 77\%$ на `searches`). Сравнение per-user Хоукс-моделей со Scaled-baseline и Joint Hawkes показывает, что при близких population-NLL они приходят к существенно разным внутренним декомпозициям (m_u, α) - первый намёк на trade-off, который мы раскрываем дальше.

Поведение на коротких train-окнах (часть II). Хоукс-сигнал в данных действительно присутствует, но он слабый, и форма регуляризации существенно меняет картину. Scaled-baseline на коротких train ($n \leq 50$ дней) вырождается фактически до Personalized GP: из-за коллинеарности EB-shrunk базы и редких target-событий Хоукс-веса прижимаются к нулю. Joint Hawkes с явной L2-регуляризацией $(\lambda_u - 1)^2$ не вырождается, но дополнительный prior не даётся «бесплатно»: на $n \leq 21$ Joint выигрывает у всех вероятностных моделей, а на промежуточных $n \in [27, 60]$ тот же $\lambda_{\ell_2} = 1$ уже излишне ограничивает модель, и Joint Hawkes на этих длинах оказывается хуже даже Personalized GP. На $n \geq 100$ обе параметризации сравниваются по test NLL, но всё ещё приходят к разным (λ_u, α) . Устойчивое преимущество Хоукс-надстройки над Personalized GP начинается с $n \approx 80$ дней. Главный практический вывод: длина train-окна имеет принципиальное значение, и универсально лучшей Хоукс-параметризации нет - выбор формы и силы регуляризации должен подстраиваться под объём доступных данных.

Структура cross-channel Хоукс-матрицы (часть III). Cross-channel матрица $\alpha \in \mathbb{R}^{3 \times 3}$ восстанавливается как осмысленная структура воронки `searches` $\rightarrow$ `to_cart` $\rightarrow$ `to_ord`. Три «обратных» коэффициента верхнего треугольника имеют плоские профили в NLL и нашими экспериментами от нуля неотличимы - мы полагаем их структурно нулевыми по convention воронки. Off-diagonal funnel-связи положительны и идентифицируются устойчиво в смысле формы профиля, хотя их точечные значения заметно меняются с длиной train-окна (Scaled-baseline на 100d систематически недообучает всю матрицу, включая off-diagonal; Joint Hawkes с активной L2 удерживает off-diagonal даже на коротких окнах за счёт явного prior'a). Диагональные коэффициенты, особенно $\alpha[to_ord \leftarrow to_ord]$, идентифицируются плохо: profile NLL почти плоский, и точечная оценка определяется в большей мере регуляризатором, чем данными. Качество идентификации диагонали падает по мере разрежения соответствующего target-канала - на богатом `searches` диагональ

выделяется хорошо, на разреженном `to_ord` - почти не идентифицируется, что согласуется с известными результатами по multivariate Hawkes [4, 5]. Sweep по $\lambda_{\ell_2} \in [0, 5]$ количественно подтверждает «переток массы» между бейзлайн-частью $\lambda_u \cdot b_t$ и Хоукс-надстройкой $\alpha^\top z$ при почти не меняющемся test NLL (размах ≤ 0.01). Это означает сверх-параметризованность модели на уровне внутренних параметров при устойчивости предсказания. После формализации идентифицируемости через 10%-gain интервалы получена финальная нижнетреугольная матрица; для её спектрального радиуса корректнее цитировать не точечную оценку, а интервал - $\text{midpoint} \approx 0.19$, левая граница ~ 0.12 , правая упёрлась в правый край сетки и фактически выше 0.26. Во всём допустимом диапазоне $\rho < 1$, Хоукс-процесс остаётся стабильным.

Практические выводы. Хоукс-модель пригодна для прогноза покупок в e-commerce, но с двумя оговорками. Во-первых, выбор параметризации зависит от длины train: на коротких окнах нужна явная регуляризация (Joint Hawkes с активным L2-prior’ом), на длинных - подходит любая из двух параметризаций. Во-вторых, точечные значения матрицы α нельзя цитировать как один «правильный» ответ: диагональные коэффициенты слабо идентифицируемы, и осмысленнее работать с интервалами. Off-diagonal funnel-связи интерпретируются устойчиво и могут использоваться в downstream-задачах (например, при декомпозиции эффекта на каналы в А/В-эксперименте), но и они требуют достаточной длины train. Бустинг-модели по абсолютному скору остаются лучшими, но без интерпретируемой структуры - выбор между Hawkes и бустингом определяется приоритетом интерпретируемости над скорингом. Per-user визуализация показывает, что Hawkes и Personalized GP при близких population-метриках дают существенно разные индивидуальные предсказания, и это надо учитывать при downstream-применении модели.

Направления дальнейшей работы. Самое естественное расширение - получить более длинные train-данные и проверить, действительно ли на них Хоукс-веса двух параметризаций сходятся, а диагональные коэффициенты становятся идентифицируемыми. Дополнительно: расширение feature-set для Hawkes-states (более длинные полураспады, категориальные контексты, session-level фичи); adaptive-регуляризация диагональных коэффициентов в духе раздельной L1/trace norm [4] или замена MLE на integrated cumulants [5]; применение к А/В-тестированию с явным cross-channel разложением эффекта; интеграция Хоукс-надстройки с нейросетевым кодером истории в духе RMTTP [3] или Neural Hawkes [7] - как способ объединить интерпретируемость α -матрицы с гибкостью deep representation’ов.

References

- [1] Hawkes A. G. **Spectra of some self-exciting and mutually exciting point processes** // Biometrika. - 1971. - Vol. 58, No. 1. - P. 83-90.
- [2] Bacry E., Mastromatteo I., Muzy J.-F. **Hawkes processes in finance** // Market Microstructure and Liquidity. - 2015. - Vol. 1, No. 1. - 1550005.
- [3] Du N., Dai H., Trivedi R., Upadhyay U., Gomez-Rodriguez M., Song L. **Recurrent marked temporal point processes: Embedding event history to vector** // Proceedings of KDD. - 2016. - P. 1555-1564.
- [4] Bacry E., Bompairé M., Gaïffas S., Muzy J.-F. **Sparse and low-rank multivariate Hawkes processes** // Journal of Machine Learning Research. - 2020. - Vol. 21, No. 50. - P. 1-32.

- [5] Achab M., Bacry E., Gaïffas S., Mastromatteo I., Muzy J.-F. **Uncovering causality from multivariate Hawkes integrated cumulants** // Journal of Machine Learning Research. - 2018. - Vol. 18, No. 192. - P. 1-28.
- [6] Fader P. S., Hardie B. G. S., Lee K. L. **RFM and CLV: Using iso-value curves for customer base analysis** // Journal of Marketing Research. - 2005. - Vol. 42, No. 4. - P. 415-430.
- [7] Mei H., Eisner J. **The neural Hawkes process: A neurally self-modulating multivariate point process** // Advances in Neural Information Processing Systems. - 2017. - Vol. 30. - P. 6754-6764.
- [8] Friedman J. H. **Greedy function approximation: A gradient boosting machine** // The Annals of Statistics. - 2001. - Vol. 29, No. 5. - P. 1189-1232.