

Применимость процессов Хокса для предсказания пользовательской активности в e-commerce

Алексей Мошкин

МКН СПбГУ, 2026

Научный руководитель: Николаев Максим Сергеевич

Цель работы

Исследовать границы применимости процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce.

Подзадачи:

1. Построить иерархию статистических моделей для устойчивого бейзлайна под Hawkes-добавку.
2. Исследовать особенности сходимости Hawkes-коэффициентов: сколько данных нужно, чтобы коэффициенты сошлись.
3. Исследовать кросс-Hawkes матрицу зависимостей между каналами воронки.
4. Сравнить Hawkes-модель с двумя явными бейзлайнами: статистической пуассоновской моделью и бустингом.

Данные

- `~10K` пользователей × `~290` дней (`2025-01-15` → `2025-10-31`).
- На каждый `(user, day)` доступны 5 поведенческих счётчиков: `searches` , `cat_to_cart` , `cat_to_ord` , `to_cart` , `to_ord` — последний и есть target.


Среднее число покупок на user-day — `~0.10` . То есть `93.7%` ячеек панели — нули, данные сильно разрежены.

Распределение числа покупок на user-day



- 93.7% user-days — нули.
- Тяжёлый правый хвост: единичные (user, day) с десятком покупок и больше.
- 18% самых активных юзеров делают 62% всех покупок.

Дневная интенсивность на полном ряду



Видно три режима:

1. первые две недели января — аномально высокая активность (NY-промо/подарки);
2. середина января → конец сентября — основное стабильное окно;
3. октябрь — снова повышенный уровень.

Что мы предсказываем и метрика качества

Для каждой пары (user, day) оцениваем интенсивность $\lambda_{\{u,t\}}$:

$$y_{u,t} \mid \lambda_{u,t} \sim \text{Poisson}(\lambda_{u,t}).$$

Метрика — mean Poisson NLL на тесте:

$$\text{NLL} = \frac{1}{N} \sum_{u,t} [\lambda_{u,t} - y_{u,t} \log \lambda_{u,t} + \log y_{u,t}!].$$

Минимум NLL $\neq 0$ — saturated Poisson floor ≈ 0.086 : даже идеальная модель не закрывает всю aleatoric uncertainty.


Дополнительно для диагностики:

$$\text{MAE} = \frac{1}{N} \sum_{u,t} |y_{u,t} - \hat{\lambda}_{u,t}|, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_{u,t} (y_{u,t} - \hat{\lambda}_{u,t})^2}.$$

Лестница базовых моделей (главы 1–4)

Шаг	Модель	Что добавили
1	Global Poisson	константа $\bar{\lambda}$
2	Rolling Poisson	rolling mean уровня
3	Rolling Seasonal	+ day-of-week
4	Personalized Gamma-Poisson	per-user μ_u через EB

Rolling baseline: динамика уровня



Видно, что стоит попробовать идеи rolling и недельной сезонности.

Personalized Gamma-Poisson — Empirical Bayes


Модель: $y_{\{u,t\}} \sim \text{Poisson}(\mu_u \cdot b_t)$, $\mu_u \sim \text{Gamma}(\alpha, \beta)$.

Posterior:

$$\hat{\mu}_u^{\text{EB}} = \frac{\alpha + Y_u}{\beta + E_u}.$$

$(\alpha, \beta) \approx (0.88, 0.88)$ оцениваются marginal MLE'ем по (Y_u, E_u) пары пар.

Per-observation NLL: лестница базовых моделей



Самый крупный шаг — персонализация (+24K нат LL); уровень и сезонность дают по чуть-чуть.

Переход глава 3 → глава 4: per-user delta-LL



- `share(personalized > rolling seasonal) = 66%`;
- юзеры с `0..2` покупок выигрывают почти всегда (`87..94%`);
- бакет `6..10` покупок — наоборот, проигрывает (`18%`): shrinkage тянет слишком сильно;
- `11+` снова выигрывает за счёт `$\mu_u$` .

Hawkes-процессы: базовое определение

Self-exciting point process — интенсивность зависит от истории своих событий:

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha \cdot \exp(-\beta(t - t_i)).$$


В дискретно-дневной форме для юзера u :

$$\lambda_{u,t} = \mu + \sum_j \alpha_j \cdot z_{u,j,t},$$

где:

- $z_{\{u,j,t\}}$ — exp-decay-сглаженная история фичи j юзера до дня t ;
- α_j — pooled Hawkes-веса.

Анализ фичей: матрица корреляций



Каналы `search_to_cart` и `search_to_ord` сильно скоррелированы с `to_cart` и `to_ord` ($r > 0.9$).

→ исключены из основной Hawkes-модели; остаётся 5 фичей вместо 7.

Scaled-baseline Hawkes (глава 6): модель и обучение

$$\lambda_{u,t} = c \cdot \mu_u^{\text{EB}} \cdot b_t + \sum_{j,m} \alpha_{j,m} z_{u,j,m,t}.$$

- baseline $\mu_u^{\text{EB}} \cdot b_t$ зафиксирован (Personalized GP из гл.4);
- 5 фичей $\times$ 2 half-life (1, 3) дня $\rightarrow$ 10 параметров α + 1 глобальный c .

Loss (регуляризованный Poisson NLL на train):

$$\mathcal{L}(c, \alpha) = -\log p(y \mid c\lambda_{\text{base}} + X\alpha) + \lambda_{\alpha} \|\alpha\|_2^2 + \lambda_c (c - 1)^2.$$

Staged: сначала EB (гл.4) $\rightarrow$ потом L-BFGS-B по (c, α) с $\alpha \geq 0$. В разделе 6.10 показано, что результат не зависит от выбора $\lambda_{\alpha}, \lambda_c$ в широком диапазоне.


Scaled-baseline Hawkes: результаты

Метрика	Pers. GP	Scaled Hawkes	Δ
Test NLL	0.4096	0.3958	-0.0138
Test LL	-210167	-203093	+7074
MAE	0.2187	0.2169	-0.0018
RMSE	0.6314	0.6272	-0.0042


Обученные параметры:

$$\hat{c} = 0.83, \quad \|\alpha\|_2 = 0.016.$$

Основной сигнал — `to_ord` ($hl=3$), плюс `searches`, `to_cart` на коротких масштабах.



Scaled-baseline Hawkes: per-user delta-LL



Tree-based подход и trade-off


GBDT (HistGradientBoostingRegressor, Poisson loss) на расширенном feature-engineering — всего 141 фича, 5 групп:

- календарь (`dow` , `days_seen` , `week_idx`);
- history по 14 исходным сигналам: `*_yesterday` , `*_sum3/7` , `*_mean7` , `*_active_days7` , `*_exp3` , `*_last_active` , `*_days_since_last_active` ;
- EMA: `*_ewm7` , `*_ewm28` , `*_ewm_gap_7_28` для `to_ord` , `to_cart` , `any_activity` ;
- общие агрегаты по заказам и активности (`orders_hist_mean` , `carts_hist_mean` , ...);
- recency и funnel-ratio: `days_since_last_*` , `ord_per_cart_7` , `*_rate_7` .

Test NLL 0.3881 — лучше всех Hawkes-моделей (+3K..7K нат). Но нет интерпретируемости: какие фичи когда работают.


Trade-off: GBDT — лучший скор, Hawkes — структурное понимание (c , μ_u , α) . В дипломе GBDT отмечен отдельным цветом — reference point, а не research-линия.

Лестница моделей (глава 9)



Переход к другим train-test (глава 10)

Blockwise CV: 13 непересекающихся 21d -блоков, каждый = 14d train + 7d test .



На коротких train картина меняется: появляется новый лидер среди вероятностных моделей — Pooled Hawkes.

Новые Hawkes-варианты (главы 7, 8)

Pooled Hawkes (гл.7): per-user multiplier'а нет вообще.

$$\lambda_{u,t} = c \cdot b_t + \alpha^\top s_{u,t}.$$

Всего 11 параметров. Персонализация через per-user states $s_{\{u,t\}}$.


Joint Hawkes (гл.8): λ_u и α обучаются одновременно с регуляризацией $(\lambda_u - 1)^2$.

$$\lambda_{u,t} = \lambda_u \cdot b_t + \alpha^\top s_{u,t}.$$

~10K + 10 параметров; нет двухступенчатости как у staged.


Train-length scan (глава 11)

Сweep по n от 15 до 198 дней; m случайных интервалов на каждое n ; $2n/3$ train + $n/3$ test.





Per-run NLL по моделям для каждого n

Train-length scan: per-run test NLL по моделям (одна панель на n)



Каждая панель — одно значение n ; точки — отдельные подвыборки, синяя черта — среднее.

Поведение Hawkes-параметров от длины train



- Scaled-baseline: до $n \approx 50$ — $\|\alpha\| = 0$, $c = 1$. Полное вырождение.
- Joint: $\|\alpha\| \approx 0.04..0.05$ — стабильный сигнал на всех n .
- Pooled: $\|\alpha\| \approx 0.08$, $c \approx 0.30$ — практически константы.

Исследование структуры Hawkes-ядер

Что учим и как теперь смотрим на параметры

Joint Hawkes на одну целевую серию:


$$\lambda_u(t) = \lambda_u \cdot b_t + \alpha^\top z_u(t)$$

- λ_u — per-user multiplier (L2-prior к 1)
- b_t — общий baseline дневной профиль
- α — Hawkes-веса по каналам-источникам

Раньше: один target `to_ord`, α — вектор по 3 источникам.

Теперь: 3 target'a × 3 source'a = матрица $\alpha \in \mathbb{R}^{3 \times 3}$ всех cross-channel взаимодействий воронки `searches → to_cart → to_ord`.


Cross-channel α : главный train vs bootstrap



- Слева: главный train 207d .
- Справа: mean $\pm$ std по 10 случайным 100d -окнам.


Эффект вырождения Hawkes на коротких train, виденный ранее в train-length scan (гл. 11), повторился и для cross-channel матрицы. Все коэффициенты на 100d существенно ниже, чем на главном 207d : diagonal searches / to_cart просели на ~37% и ~51% , off-diagonal — на 30..63% , а self- $\alpha[\text{to_ord} \leftarrow \text{to_ord}]$ коллапсирует практически в ноль (0.019 $\rightarrow$ 0.002 , CV 148%).

Регуляризация: Scaled vs Joint $\lambda_{l2}=1$ vs Joint $\lambda_{l2}=0$




Коэффициенты кросс-Hawkes матрицы сильно зависят от регуляризации. При этом регуляризация может быть структурной — как между Personalized Gamma-Poisson и Joint Hawkes — либо численной, как внутри самого Joint Hawkes ($\lambda_{l2} = 1$ vs $\lambda_{l2} = 0$).

Регуляризация на 207d : масса vs скор




С ростом λ_{l_2} масса перетекает из baseline $\lambda_u \cdot b_t$ в Hawkes $\alpha^T z$. Сильнее всего на to_ord.

Регуляризация сильно перераспределяет массу, но слабо влияет на скор.



Test NLL почти не меняется: range $\approx 0.009 / 0.005 / 0.004$ нат/н.


Где λ_{l2} меняет α , а где нет



- Колонка `to_ord` — уверенно обнуляется.
- Внедиагональные элементы относительно устойчивы ($\pm 2..10\%$ по $\lambda_{l2} \in [0, 5]$).
- Диагональные элементы устойчивы в меньшей мере. Особенно сильно меняется $\alpha[\text{to_ord} \leftarrow \text{to_ord}]$: +82% ($0.030 \rightarrow 0.055$).

Test NLL по сетке почти не двигается → на 207d train существует множество (λ_u, α) -решений с одинаковым качеством; диагональные элементы пробегают широкий диапазон внутри него.

Profile NLL по 9 коэффициентам — train и test



Для каждой пары (target, source) : фиксируем $\alpha[i, j]$ на широкой сетке из 11 значений, остальные параметры оптимизируем по NLL, считаем train NLL (слева) и test NLL (справа).

- Топология NLL на внедиагональных элементах совпадает для train и test. Для диагональных элементов структура другая.
- Структура слабо зависит от регуляризации, с которой обучаем 11 коэффициентов: фиты с $\lambda_{l2} = 1$ и $\lambda_{l2} = 0$ дают схожие картины.

Асимметрия между диагональными и внедиагональными коэффициентами

Эмпирическое наблюдение: диагональные Hawkes-элементы дрейфуют под изменением регуляризации; внедиагональные — более стабильны.

Причина — коллинеарность history-state и baseline:

$$\lambda_{u,t}^{(k)} = \underbrace{\lambda_u^{(k)} \cdot b_t}_{\text{baseline}} + \underbrace{\alpha_{kk} z_{u,t}^{(k)}}_{\text{диагональный Hawkes}} + \sum_{j \neq k} \alpha_{kj} z_{u,t}^{(j)}$$


- Для диагональных: $\mathbb{E}[z_{u,t}^{(k)}] \propto \lambda_u^{(k)} \cdot b_t$ — тот же сигнал, что и baseline. Линейная комбинация двух почти коллинеарных регрессоров $\rightarrow$ ridge-подобный «жёлоб» в parameter space.
- Для внедиагональных: $z_{u,t}^{(j)}$ описывает другой канал, не дублирует baseline $\rightarrow$ коэффициент идентифицируем.

В литературе:

- Bacry, Bompairé, Gaïffas, Muzy (2020, JMLR) — предлагают separate regularization для диагональных (ℓ_1) и внедиагональных (trace norm) — именно потому, что диагональ absorbs baseline mass.
- Achab, Bacry, Gaïffas, Mastromatteo, Muzy (2018, JMLR) — отказываются от MLE в пользу integrated cumulants, чтобы обойти diagonal/baseline non-identifiability.

Интервалы 10%-gain над baseline

10%-gain intervals over Personalized GP baseline (threshold = $\min + 0.1 \cdot (\text{PG} - \min)$, unregularized fit, $\lambda_{t_2} = 0$)




- Верхний треугольник: данные не реагируют $\rightarrow$ структурно нули.
- Диагональ: широкие интервалы ($\alpha[s \leftarrow s] \in [0.12, 0.26]$, self- to_ord $\in [0.02, 0.10]$).
- Нижний треугольник: узкие ($\text{to_ord} \leftarrow s \in [0.008, 0.014]$).

Даже на 207d многие коэффициенты либо незначимы, либо лежат в широком интервале.

Финальная Hawkes-матрица: midpoint'ы

awkes interaction matrix (10%-gain midpoints, upper triangle zeroed)
 $\rho(M) = 0.1884$



target ↓ \ src →	s	c	o
searches	0.188	0	0
to_cart	0.025	0.095	0
to_ord	0.011	0.014	0.059

Матрица нижнетреугольная по convention воронки →
собственные значения = диагональ:

- $|eigvals| = [0.059, 0.095, 0.188]$
- $\rho(M) = 0.188$ — $\rho < 1$, далеко от explosion-порога.

Выводы

1. Персонализация с байесовской регуляризацией — крупный шаг по NLL. Добавление Hawkes-ядер улучшает метрику ещё сильнее, и эта добавка стабильная.
2. Hawkes-сигнал в данных есть — как видно из первого пункта. Однако он слабый и неоднородный по разным кросс-Hawkes зависимостям. Из-за сильной корреляции между диагональным Hawkes-сигналом и общим baseline'ом диагональные элементы учатся сложно: большая неопределённость по ним сохраняется даже на 207d train. Важно, что это структурная особенность, а не огрехи обучения.
3. Бустинг даёт улучшение, но небольшое — потолок предсказательной силы низкий из-за шума. Применимость ограничена сложностью интерпретации.