

Применимость процессов Хокса для предсказания пользовательской активности в e-commerce

Алексей Мошкин

МКН СПбГУ, 2026

Цель работы

Исследовать границы применимости процессов Хокса для предсказания дневной интенсивности покупок пользователя в e-commerce.

Подзадачи:

1. Построить иерархию вероятностных моделей от простых baseline'ов до Hawkes-вариантов.
2. Исследовать, как длина train-окна влияет на качество обучения Hawkes-модели.
3. Понять, где Hawkes-надстройка приносит реальную ценность, а где сливается с per-user multiplier'ом.

Данные

- `~10K` пользователей × `~290` дней (`2025-01-15` → `2025-10-31`).
- На каждый `(user, day)` доступны 5 поведенческих счётчиков: `searches` , `cat_to_cart` , `cat_to_ord` , `to_cart` , **`to_ord`** — последний и есть **target**.


Среднее число покупок на user-day — `~0.10` . То есть **93.7%** ячеек панели — нули, данные сильно разрежены.

Распределение числа покупок на user-day



- **93.7%** user-days — нули.
- Тяжёлый правый хвост: единичные (user, day) с десятком покупок и больше.
- **18%** самых активных юзеров делают **62%** всех покупок.

Дневная интенсивность на полном ряду



Видно три режима:

1. **первые две недели января** — аномально высокая активность (NY-промо/подарки);
2. **середина января → конец сентября** — основное стабильное окно;
3. **октябрь** — снова повышенный уровень.

Что мы предсказываем и метрика качества

Для каждой пары (user, day) оцениваем интенсивность $\lambda_{\{u,t\}}$:

$$y_{u,t} \mid \lambda_{u,t} \sim \text{Poisson}(\lambda_{u,t}).$$

Метрика — **mean Poisson NLL** на тесте:

$$\text{NLL} = \frac{1}{N} \sum_{u,t} [\lambda_{u,t} - y_{u,t} \log \lambda_{u,t} + \log y_{u,t}!].$$

Минимум NLL $\neq 0$ — **saturated Poisson floor** ≈ 0.086 : даже идеальная модель не закроет всю aleatoric uncertainty.


Дополнительно для диагностики:

$$\text{MAE} = \frac{1}{N} \sum_{u,t} |y_{u,t} - \hat{\lambda}_{u,t}|, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_{u,t} (y_{u,t} - \hat{\lambda}_{u,t})^2}.$$

Лестница базовых моделей (главы 1–4)

Шаг	Модель	Что добавили
1	Global Poisson	константа $\bar{\lambda}$
2	Rolling Poisson	rolling mean уровня
3	Rolling Seasonal	+ day-of-week
4	Personalized Gamma-Poisson	per-user μ_u через EB

Rolling baseline: динамика уровня



Видно, что стоит попробовать идеи rolling и недельной сезонности.

Personalized Gamma-Poisson — Empirical Bayes


Модель: $y_{\{u,t\}} \sim \text{Poisson}(\mu_u \cdot b_t)$, $\mu_u \sim \text{Gamma}(\alpha, \beta)$.

Posterior:

$$\hat{\mu}_u^{\text{EB}} = \frac{\alpha + Y_u}{\beta + E_u}.$$

$(\alpha, \beta) \approx (0.88, 0.88)$ оцениваются marginal MLE'ем по (Y_u, E_u) пары пар.

Per-observation NLL: лестница базовых моделей



Самый крупный шаг — персонализация (+24K нат LL); уровень и сезонность дают по чуть-чуть.

Переход глава 3 → глава 4: per-user delta-LL



- `share(personalized > rolling seasonal) = 66%`;
- юзеры с `0..2` покупок выигрывают почти всегда (`87..94%`);

Hawkes-процессы: базовое определение

Self-exciting point process — интенсивность зависит от истории своих событий:

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha \cdot \exp(-\beta(t - t_i)).$$


В дискретно-дневной форме для юзера u :

$$\lambda_{u,t} = \mu + \sum_j \alpha_j \cdot z_{u,j,t},$$

где:

- $z_{\{u,j,t\}}$ — exp-decay-сглаженная история фичи j юзера до дня t ;
- α_j — pooled Hawkes-веса.

Анализ фичей: матрица корреляций



Каналы `search_to_cart` и `search_to_ord` сильно скоррелированы с `to_cart` и `to_ord` ($r > 0.9$).

→ **исключены** из основной Hawkes-модели; остаётся 5 фичей вместо 7.

Scaled-baseline Hawkes (глава 6): модель и обучение

$$\lambda_{u,t} = c \cdot \mu_u^{\text{EB}} \cdot b_t + \sum_{j,m} \alpha_{j,m} z_{u,j,m,t}.$$

- baseline $\mu_u^{\text{EB}} \cdot b_t$ зафиксирован (Personalized GP из гл.4);
- 5 фичей $\times$ 2 half-life (1, 3) дня $\rightarrow$ 10 параметров α + 1 глобальный c .

Loss (регуляризованный Poisson NLL на train):

$$\mathcal{L}(c, \alpha) = -\log p(y \mid c\lambda_{\text{base}} + X\alpha) + \lambda_{\alpha} \|\alpha\|_2^2 + \lambda_c (c - 1)^2.$$

Staged: сначала EB (гл.4) $\rightarrow$ потом L-BFGS-B по (c, α) с $\alpha \geq 0$. В разделе 6.10 показано, что результат не зависит от выбора $\lambda_{\alpha}, \lambda_c$ в широком диапазоне.


Scaled-baseline Hawkes: результаты

Метрика	Pers. GP	Scaled Hawkes	Δ
Test NLL	0.4096	0.3958	-0.0138
Test LL	-210167	-203093	+7074
MAE	0.2187	0.2169	-0.0018
RMSE	0.6314	0.6272	-0.0042


Обученные параметры:

$$\hat{c} = 0.83, \quad \|\alpha\|_2 = 0.016.$$

Основной сигнал — `to_ord` ($hl=3$), плюс `searches`, `to_cart` на коротких масштабах.



Scaled-baseline Hawkes: per-user delta-LL



Tree-based подход и trade-off


GBDT (HistGradientBoostingRegressor, Poisson loss) на расширенном feature-engineering — всего 141 фича, 5 групп:

- календарь (dow , days_seen , week_idx);
- history по 14 исходным сигналам: *_yesterday , *_sum3/7 , *_mean7 , *_active_days7 , *_exp3 , *_last_active , *_days_since_last_active ;
- ЕМА: *_ewm7 , *_ewm28 , *_ewm_gap_7_28 для to_ord , to_cart , any_activity ;
- общие агрегаты по заказам и активности (orders_hist_mean , carts_hist_mean , ...);
- recency и funnel-ratio: days_since_last_* , ord_per_cart_7 , *_rate_7 .

Test NLL 0.3881 — лучше всех Hawkes-моделей (+3K..7K нат). Но нет интерпретируемости: какие фичи когда работают.


Trade-off: GBDT — лучший скор, Hawkes — структурное понимание (c , μ_u , α) . В дипломе GBDT отмечен отдельным цветом — reference point, а не research-линия.

Лестница моделей (глава 9)



Переход к другим train-test (глава 10)

Blockwise CV: 13 непересекающихся 21d -блоков, каждый = 14d train + 7d test .



На коротких train картина меняется: появляется новый лидер среди вероятностных моделей — Pooled Hawkes.

Новые Hawkes-варианты (главы 7, 8)

Pooled Hawkes (гл.7): per-user multiplier'a **нет вообще**.

$$\lambda_{u,t} = c \cdot b_t + \alpha^\top s_{u,t}.$$

Всего 11 параметров. Персонализация через **per-user states** $s_{\{u,t\}}$.


Joint Hawkes (гл.8): λ_u и α обучаются **одновременно** с регуляризацией $(\lambda_u - 1)^2$.

$$\lambda_{u,t} = \lambda_u \cdot b_t + \alpha^\top s_{u,t}.$$

~10K + 10 параметров; нет двухступенчатости как у staged.


Train-length scan (глава 11)

Сweep по n от 15 до 198 дней; m случайных интервалов на каждое n ; $2n/3$ train + $n/3$ test.





Per-run NLL по моделям для каждого n

Train-length scan: per-run test NLL по моделям (одна панель на n)



Каждая панель — одно значение n ; точки — отдельные подвыборки, синяя черта — среднее.

Поведение Hawkes-параметров от длины train



- **Scaled-baseline:** до $n \approx 50$ — $\|\alpha\| = 0$, $c = 1$. Полное вырождение.
- **Joint:** $\|\alpha\| \approx 0.04 \dots 0.05$ — стабильный сигнал на всех n .
- **Pooled:** $\|\alpha\| \approx 0.08$, $c \approx 0.30$ — практически константы.

Выводы

1. **Персонализация с байесовской регуляризацией** — крупный шаг по NLL. Добавление Hawkes-ядер улучшает метрику ещё сильнее, и эта добавка **стабильная**.
2. Данные очень шумные. При похожих по форме моделях остро встаёт вопрос **как обучаться** — именно он порождает то, что Hawkes в итоге представлен **тремя близкими вариантами**.
3. **Pooled Hawkes** — максимально простой, не переобучается и подходит для очень коротких train-окон; но на длинных проигрывает более сложным **Scaled-baseline** и **Joint Hawkes**.
4. Эффект от Hawkes-ядер поверх сильного personalized Poisson **сохраняется** на всех режимах. Просто в зависимости от размера train **нужно выбирать правильную Hawkes-параметризацию**.
5. **Бустинг** даёт улучшение, но небольшое — потолок предсказательной силы низкий из-за шума. Применимость ограничена сложностью интерпретации.